


第6章 无监督学习

主讲：陈建海


浙江大学计算机科学与技术学院
2024年10月

经典复杂问题求解


装箱问题



倒水问题

人工智能
经典问题求解算法—
求解方法

- (1) 贪心法
- (2) 分治法
- (3) 回溯法
- (4) 动态规划



求解方法种类

状态搜索空间法

启发式搜索求解

遗传算法求解

模拟退火求解

约束满足求解

典型问题案例

八数码

走迷宫

旅行推销员


拼图游戏

数独游戏

□ 机器学习的定义：


- 已知给出一个数据集 **Dataset** (X, Y)， Y 与 X 存在某种对应关系， Y 称为 X 的标签。
- 现在要寻找一个函数或模型 F ，使得 F 作用在 X 上之后的结果是 $Y' = F(X)$ ，满足 $|Y - Y'|$ 尽可能小， Y' 最大化接近 Y 。
- 我们把利用机器的算法寻找函数 F 的过程称为 **机器学习**。

- 每一对 X, Y 又叫 **样本**，总个数叫 **样本大小**
- Y 的所有可能取值叫 **样本空间**，**Dataset** 是样本空间的一个随机抽样




提纲

- 1 理解无监督学习
- 2 聚类与降维
- 3 理解强化学习
- 4 强化学习经典算法
- 5 强化学习应用案例



无监督学习是机器学习的一种方法，旨在从**没有标签的数据**中识别潜在的模式或结构。与监督学习不同，无监督学习不依赖于已知的输出标签。

	监督学习	无监督学习
训练数据	带标签的数据集	不带标签的数据集
学习目标	预测输出或分类	发现数据的潜在结构或模式
模型评估	通过准确率、F1-score 等进行评估	通常通过轮廓系数、聚类效果等进行评估
数据标记	需要人工标记	无需人工标记



讨论：下列哪些属于无监督学习

- 顾客分群
- 房价预测
- 图像分类
- 异常检测
- 手写数字识别
- 情感分析

聚类

- 目标是将相似的数据点分组在一起，形成"簇"（cluster）。

聚类算法：

- K-means
- 层次聚类
- DBSCAN

降维

- 就像是数据的“瘦身”过程。降维将高维数据转换为低维表示，同时巧妙地保留了原始数据中最重要的信息。

降维算法：

- 主成分分析 (PCA)
- t-SNE
- 自编码器

异常检测

- 发现潜在的异常样本，通常指示错误、欺诈或其他重要事件。


提纲

- 1 理解无监督学习
- 2 聚类与降维
- 3 理解强化学习
- 4 强化学习经典算法
- 5 强化学习应用案例

2 聚类

定义：聚类是一种无监督学习技术，旨在将数据集分成若干组，使得同组内的样本相似度高，而不同组间的样本相似度低。

K-means是最常用的聚类算法之一，主要步骤为：(1)随机初始化若干个中心点，周围散布着未分类的数据点；(2)将每个数据点分配给最近的中心，形成初步的簇；(3)重新计算每个簇的中心点。



2 聚类案例-鸢尾花分析

在鸢尾花案例中，聚类就像是在没有任何先验知识的情况下，仅仅根据花的特征（花萼和花瓣的长度和宽度）来将它们分类。以下代码使用K-means聚类算法实现了对鸢尾花数据集的分类，让我们逐步分析代码的各个部分。

1. 数据准备

```
iris = datasets.load_iris()↵  
X = iris.data↵  
y = iris.target↵  
↵  
scaler = StandardScaler()↵  
X_scaled = scaler.fit_transform(X)↵
```

首先加载鸢尾花数据集。X包含特征数据，y包含真实的类别标签。然后，我们使用StandardScaler对数据进行标准化。标准化的目的是将所有特征调整到相同的尺度，这对K-means算法很重要，因为它基于距离计算。

2 聚类案例-鸢尾花分析

2.创建和训练K-means模型

```
kmeans = KMeans(n_clusters=3, random_state=42)↵  
kmeans.fit(X_scaled)↵
```

这里我们创建一个K-means模型，指定簇的数量为3（因为鸢尾花有3个品种）。random_state=42确保结果可重复。fit方法执行聚类过程，包括初始化中心点、分配数据点到最近的簇、更新簇中心等步骤，直到收敛。

3.获取聚类结果

```
y_kmeans = kmeans.predict(X_scaled)↵
```

predict方法将每个数据点分配到最近的簇。y_kmeans包含每个数据点的簇标签。

2 聚类案例-鸢尾花分析

4. 可视化结果

```
plt.figure(figsize=(12, 5))  
plt.subplot(121)  
plt.scatter(X[:, 0], X[:, 1], c=y, cmap='viridis')  
# ... (省略部分代码)  
plt.subplot(122)  
plt.scatter(X[:, 0], X[:, 1], c=y_kmeans, cmap='viridis')  
plt.scatter(kmeans.cluster_centers_[ :, 0], kmeans.cluster_centers_[ :, 1],  
            s=300, c='red', marker='*', label='聚类中心')  
# ... (省略部分代码)
```

这部分代码创建两个子图：左图显示原始数据的真实类别，右图显示K-means聚类的结果。我们只使用前两个特征（萼片长度和宽度）来创建2D散点图。在右图中，我们还标出了每个簇的中心点。

2 聚类案例-鸢尾花分析

5.评估聚类结果

```
accuracy = accuracy_score(y, y_kmeans)
print(f"聚类准确率: {accuracy:.2f}")
```

这里我们计算聚类的准确率。需要注意的是，K-means是一种无监督学习算法，通常不会用准确率来评估。但在这个例子中，由于我们知道真实的类别标签，所以可以用它来了解聚类效果。

6.分析簇的组成

```
for i in range(3):
    cluster = np.where(y_kmeans == i)[0]
    print(f"\n簇 {i} 的组成:")
    for iris_type in range(3):
        count = np.sum(y[cluster] == iris_type)
        print(f" {iris.target_names[iris_type]}: {count}")
```


这段代码分析每个簇的组成。它计算每个簇中不同鸢尾花品种的数量，帮助我们理解聚类的效果和每个簇的特点。

2 降维

定义：降维是将高维数据转换为低维表示的过程，以简化数据集并降低计算复杂性。

主成分分析（Principal Component Analysis, PCA）是最常用的降维技术之一。

主要步骤为：(1)数据中心化；(2)计算协方差矩阵；(3)计算特征向量和特征值；(4)选择主成分。



以下代码展示了如何使用主成分分析（PCA）对鸢尾花数据集进行降维和可视化。让我们逐步解析代码的每个部分。

1.数据准备

```
iris = datasets.load_iris()↵  
X = iris.data↵  
y = iris.target↵
```

这部分代码加载了sklearn自带的鸢尾花数据集。X包含了四个特征（花萼长度、花萼宽度、花瓣长度、花瓣宽度），y是对应的标签（鸢尾花的种类）。

2.数据标准化

```
scaler = StandardScaler()↵  
X_scaled = scaler.fit_transform(X)↵
```

在应用PCA之前，我们首先对数据进行标准化。这一步很重要，因为PCA对数据的尺度很敏感。标准化确保了所有特征都在相同的尺度上，防止某些特征由于其数值范围较大而主导PCA的结果。

3.应用PCA

```
pca = PCA()  
X_pca = pca.fit_transform(X_scaled)
```

这里我们创建了一个PCA对象，并使用fit_transform方法对标准化后的数据进行转换。X_pca就是转换后的数据，其中每一列对应一个主成分。

4.分析主成分

```
explained_variance_ratio = pca.explained_variance_ratio_
```

explained_variance_ratio_ 告诉我们每个主成分解释了多少比例的方差。这个比例反映了每个主成分的重要性。

5.分析主成分的组成

```
print("主成分的特征向量:")  
for i, component in enumerate(pca.components_):  
    print(f"PC{i+1}: {component}")  
  
print("\n 原始特征与主成分的相关性:")  
for i, component in enumerate(pca.components_):  
    correlations = component * np.sqrt(pca.explained_variance_[i])  
    print(f"PC{i+1}:")  
    for j, corr in enumerate(correlations):  
        print(f"  {iris.feature_names[j]}: {corr:.3f}")
```

这一部分代码帮助我们理解每个主成分的具体含义：

首先打印出每个主成分的特征向量，告诉我们每个原始特征对主成分的贡献。

然后计算并打印原始特征与主成分的相关性。这告诉我们每个主成分与原始特征的关系强度和方向。

通过分析这些信息，我们可以给每个主成分一个有意义的解释，例如"第一主成分可能代表花的整体大小"或"第二主成分可能代表花瓣与花萼的比例"。

