

第7章 强化学习

主讲：陈建海


浙江大学计算机科学与技术学院
2024年10月

提纲

- 1 理解强化学习
- 2 强化学习经典算法
- 3 强化学习应用案例


提纲

- 1 理解强化学习
- 2 强化学习经典算法
- 3 强化学习应用案例



强化学习（Reinforcement Learning, RL）是一种机器学习方法，通过与环境的交互学习最优策略，以最大化累积奖励。

强化学习的核心思想：智能体（Agent）在环境（Environment）中采取行动（Action），根据环境反馈（Reward）调整其行为，以改善未来的决策。



- **智能体(Agent)**是执行动作的实体。它通过观察环境状态并做出决策来学习最佳行为。
 - 三个关键特征：自主性、适应性、目标导向
 - 现实应用实例：游戏领域中如国际象棋或围棋中的AI程序、工业生产中工厂里的装配机器人、电子商务领域推荐系统中的算法、交通领域中自动驾驶车辆的控制系统
- **环境(Environment)**是智能体交互的场所，包含所有外部因素及状态的集合。
 - 三个突出的特征：动态性、不确定性、部分可观察
 - 功能：提供状态信息给智能体；根据智能体的动作反馈奖励和新的状态。
- **状态(State)**可以被看作是智能体在决策过程中的信息基础，包含了做出明智决策所需的所有关键信息。
 - 三个关键特征：信息完整性、马尔可夫性、表示方式多样性

- **动作(Action)**是智能体与环境交互的核心方式，代表了智能体可以采取的所有可能行为，是智能体影响环境、改变状态并最终获得奖励的直接手段。
- **奖励(Reward)**是环境给予智能体的直接反馈，用于评估智能体在特定状态下采取某个动作的优劣程度。
 - 奖励函数的设计直接决定了智能体最终学到的行为。
- **策略(Policy)** 是智能体在给定状态下采取动作的规则，可以是确定性的或随机的。
 - 确定性策略：在特定状态下，总是选择相同的动作。
 - 随机策略：在特定状态下，以一定概率选择不同的动作。

3 强化学习与监督学习的区别

1. 强化学习的最显著特点是其交互性。


在传统的监督学习中，我们通常使用预先准备好的**静态数据集**进行训练。

而强化学习则是一个**动态的、持续的**学习过程。这种交互性使得强化学习能够适应变化的环境，并在实时情况下做出决策。

2. 强化学习通常涉及延迟反馈

在监督学习中，每个训练样本都有即时的反馈——即正确的标签或输出。

但在强化学习中，智能体的行为可能不会立即得到反馈。



3 强化学习与监督学习的区别

3.探索与利用的平衡


这是强化学习中一个独特而关键的概念。智能体需要在尝试新的、未知的策略(探索)和使用已知的有效策略(利用)之间取得平衡。

在其他机器学习方法中，这种权衡并不常见。

4.目标


在监督学习中，我们通常致力于**最小化预测误差**，例如在回归问题中最小化均方误差。

而强化学习的目标是**最大化长期累积奖励**。这意味着智能体不仅要考虑即时的结果，还要考虑其行为对未来可能产生的影响。



马尔可夫决策过程 (Markov Decision Process, MDP) 是强化学习和决策理论中的一种数学模型，用于描述智能体在环境中如何做出决策。

MDP的核心思想：系统的下一个状态只取决于当前状态和所采取的动作，而与之前的历史无关。这就是所谓的"马尔可夫性质"。



马尔可夫决策过程由五个主要部分组成，通常表示为一个元组(S , A , P , R , γ)。

- 1. 状态集合(S):** 状态集合 S 包含了环境可能处于的所有状态。在棋类游戏的例子中，一个状态就是一个特定的棋盘布局。
- 2. 动作集合(A):** 动作集合 A 包含了智能体在任何给定状态下可以执行的所有可能动作。在棋类游戏中，动作就是你可以进行的所有合法移动。动作集合也可以是连续的(如机器人的转向角度)或离散的(如上、下、左、右移动)。
- 3. 转移概率函数(P):** 转移概率函数 P 定义了从一个状态采取某个动作后转移到另一个状态的概率。它捕捉了环境的动态特性。例如，在一个简单的网格世界中，机器人向前移动一步可能有80%的概率成功，20%的概率留在原地(可能由于地面湿滑)。
- 4. 奖励函数(R):** 奖励函数 R 定义了特定状态下采取某个动作并转移到新状态时获得的即时奖励。奖励可以是正面的(如在游戏中得分)，也可以是负面的(如消耗能量)。奖励函数是强化学习中驱动智能体学习的关键。
- 5. 折扣因子(γ):** 折扣因子 γ 是一个介于0和1之间的数，用于平衡即时奖励和长期奖励的重要性。较低的 γ 值使智能体更注重即时奖励，而较高的 γ 值则使智能体更注重长期奖励。这在处理具有延迟奖励的问题时特别重要。

提纲

- 1 理解强化学习
- 2 强化学习经典算法
- 3 强化学习应用案例

4 Q-learning算法

Q-learning是一种无模型的强化学习算法，用于通过与环境的交互学习最优策略。

核心思想：通过维护一个Q值表，记录每个状态-动作对的预期收益，从而指导智能体的决策。

Q表记录了在游戏的每个场景（状态）下，采取每个可能动作的预期得分。例如，假设这是一个简单的迷宫游戏，Q表可能看起来像这样：

位置	向上移动	向下移动	向左移动	向右移动
A1	-5	10	0	5
A2	20	-10	15	0
B1	0	5	-5	10
...	...	...	...	...

这个表格告诉我们：


- 在位置A1，向下移动可能是最好的选择（得分10）
- 在位置A2，向上移动似乎最有利（得分20）
- 在位置B1，向右移动可能会有好结果（得分10）

Q-learning不仅考虑即时的奖励，还会考虑这个动作对未来可能带来的影响。

在我们的迷宫游戏中，可能向右移动立即没有得分，但它把我们带到了一个有很多得分机会的新位置。Q-learning会学会权衡这种即时奖励和长期利益。

学习过程

- 初始化：开始时，Q表中的所有值通常设为零或随机小值。随后设定学习参数，包括学习率（决定新经历对我们判断的影响程度）以及折扣因子（决定我们看重未来奖励的程度）。
- 探索与利用：
 - 探索（Exploration）：智能体尝试新的动作，以获得更多的信息。
 - 利用（Exploitation）：智能体选择当前已知的最佳动作，基于Q表中的值进行决策。



探索过程

1. **观察当前位置：**假设我们在位置B2，周围有墙壁、空地和一个看起来可疑的地砖。
2. **选择动作：**大多数时候，我们会选择经验笔记中显示为最佳的动作，这叫做**"利用"**我们的知识。偶尔我们会随机选择一个动作，哪怕它在我们的笔记里看起来不是最好的。这叫做**"探索"**，为的是发现可能被忽视的好机会。假设这次我们决定向右移动。
3. **执行动作，观察结果：**我们向右移动到B3，发现我们失去了10分。
4. **更新经验笔记：**现在我们要更新我们对“在B2向右移动”这个动作的评价。更新公式可以理解为：新评分 = 旧评分 + 新鲜度 * (即时奖励 + 远见 * 下一位置的最佳动作评分 - 旧评分)。假设：旧评分是0，新鲜度（学习率）是0.1，即时奖励是-10（掉入陷阱），远见（折扣因子）是0.9，B3位置的最佳动作评分（假设）是5，那么新评分 = $0 + 0.1 * (-10 + 0.9 * 5 - 0) = -0.55$ 。我们将B2位置向右移动的评分从0更新为-0.55，反映了这是个不太好的选择。
5. 移动到新位置（B3），重复步骤1-4。
6. 当到达终点或失败时，开始新一轮探索。

策略梯度算法是一种强化学习方法，通过直接优化策略来提高智能体在环境中的表现。与基于值的方法（如Q-learning）不同，策略梯度算法关注于学习策略本身，而不是状态-动作值函数。

核心思想：直接调整策略以最大化预期的总奖励。

优点： 可以直接优化策略，适用于高维和连续的动作空间，适合复杂任务。

可以直接学习复杂的策略，无需构建值函数。

在理论上，策略梯度算法可以收敛到最优策略，特别是当使用足够的探索时。

缺点： 可能受到方差较大的影响，需要有效的梯度估计。

收敛速度通常较慢，需要更多的样本来达到满意的性能。

算法性能往往对学习率、折扣因子等超参数非常敏感，调参过程可能较为复杂。

在某些情况下，仍可能陷入局部最优解。

提纲


- 1 理解强化学习
- 2 强化学习经典算法
- 3 强化学习应用案例

强化学习作为人工智能和机器学习的一个重要分支，已经在多个领域展现出巨大的潜力和实际价值。

游戏AI：游戏AI是强化学习最引人注目的应用领域之一，从传统的棋类游戏到现代的电子游戏，强化学习都展现出了惊人的能力。



机器人控制：强化学习在机器人控制领域的应用正在从实验室逐步走向现实世界。强化学习被用来教会双足机器人如何在各种地形上行走和保持平衡。



自动驾驶：自动驾驶是强化学习的一个重要应用领域，涉及复杂的感知、决策和控制问题。强化学习算法可以学习在各种道路条件下的最佳加速、减速和转向策略。



