



浙江大学
ZHEJIANG UNIVERSITY



第8章 人工神经网络

陈建海

2024年11月4日



课程二维码

本课件仅供教学使用，未经许可不得转载



重点回顾





综合实践要求

- 1、参照软件界面参考图，使用PyQT设计软件的用户界面，并在实际的开发中挖掘新的需求
- 2、以AlexNet为基础，设计不同参数的CNN模型（三个以上）
- 3、设计不同参数的MLP模型（三个以上）
- 4、用fer2013数据集进行模型训练，可采用Pytorch、Tensorflow、scikit-learn、PaddlePaddle中的任何一个或几个。也可以自己找，比如股票预测、蛋白质结构预测
- 5、对每个模型进行评价，作出ROC曲线，并撰写实验报告



免费的电子书芸悦读 <https://www.icaifang.cn/home>




<https://m-tob.jd.com/ebook/30836897>



提纲

- 1 图像识别技术
- 2 感知机模型
- 3 单隐含层MLP
- 4 损失函数
- 5 BP算法



深度学习 (Deep Learning , DL) 是机器学习的一个子集，它使用多层人工神经网络来精准完成诸如物体检测、语音识别、语言翻译等任务。

基本思想：通过构建**多层网络**，对目标进行**多层表示**，以期通过**多层的高层次特征**来表示数据的**抽象语义信息**，从而获得更好的**特征鲁棒性**。


主要模型

- 1、多层感知机 (MLP)
- 2、卷积神经网络
- 3、循环神经网络
- 4、Transformer
- 5、扩散模型



多层网络结构：


由**多层神经元**组成，包括**输入层**、**隐藏层**和**输出层**。这些层之间通过**权重和偏置**进行**连接**，形成**复杂的网络结构**。




- **自动特征提取**：自动从原始数据中提取有用的特征，无需人工设计特征工程。
- **非线性激活函数**：深度学习模型中通常使用非线性激活函数（如ReLU、sigmoid等），使得模型能够学习复杂的非线性关系。

- **大规模数据处理能力**：借助现代计算技术和大数据资源，深度学习模型能够处理大规模数据集，提高模型的准确性和泛化能力。

常用深度学习模型




CNN卷积神经



RNN循环神经




GAN生成对抗




DQN强化神经




GNN图神经



LSTM长短期



Transformer




深度置信网络


早期视频分析案例




车辆识别-减影法



Morris水迷宫



小鼠穿梭箱



视频分解成图像：视频可以解码成一帧帧的图片，每秒24帧

图像灰度化：将彩色的RGB图像（3通道）转换成单通道灰度图像

图像二值化：设定一个阈值范围，将目标与背景区别开来



边缘检测：通过一系列的算子，提取目标的边缘

目标识别：通过**提取一系列的特征**，识别**目标的特性**并完成计算




其他动物行为学分析


人眼识别物体的基本过程



大脑中的神经网络




大脑是由约1千亿个神经元组成的，这些神经元都是同质的，而且功能很**简单**，但当大量神经元通过**突触**连接在一起时，就可以完成很**复杂**的功能。



神经元之间的连接是**可学习的**，我们就是通过这种能力，慢慢学会了各种技能

电镜下试图建立连接的2个神经元



婴儿出生以后大脑中神经元连接的数量随着年龄增长而逐渐增加。到一定年龄以后，连接数量不再增加，但连接的结构性会增强

神经元的**“全或无”**现象：只有当外来刺激有足够大的强度，才能引起神经元细胞的兴奋并产生动作电位，但再增加刺激强度并不会导致动作电位的幅度发生变化。神经元细胞产生的动作电位沿着细胞膜向周围传播，传播的范围和距离也不会随刺激强度的不同而不同。




感知机模型

神经元模型M-P模型



第 i 个神经元



输入： x_{ij} 连接强度： w_{ij}

内部状态： Net_i

t 时刻的激活状态： $a_i(t)$

传递函数： $T_i=F_i$

θ_i ：阈值，又称偏置值

M-P模型中， w_{ij} 和 θ_i 是可变参数，可以通过经验或者学习获得。该模型的信息处理包括三个部分：


- (1) 完成信息输入并与连接系数做内积运算 net_i ；
- (2) 将内积运算结果通过传递函数 T ；
- (3) 由阈值函数判决，若输出值大与阈值门限，则该神经元被激活，否则处于抑制状态。

阈值函数也称阀门，它是根据相关单元的权重模拟二进制。阈值函数可以描述为二值函数：




$$f_i(a_i) \begin{cases} 1 & \text{if } a_i > \theta_i \\ 0 & \text{if } a_i \leq \theta_i \end{cases}$$

该函数也称阶跃函数。

$$y_i = T_i(net_i + \theta_i) = T_i\left(\sum_{j=1}^n w_{ij}x_j + \theta_i\right)$$



感知机模型



输入 X 可以是一个任意维度 n 的向量 $X = [x_1, x_2, \dots, x_n]$, W 是 X 的权重向量, $W = [w_1, w_2, \dots, w_n]$, 网络 $\Sigma = WX^T + b$ 完成线性变换。 f 是激活函数, 完成非线性变换。

要求：根据图写出公式表示（形式化表示）

感知机案例-分类



例 8-1：用感知机模型设计二分类问题（线性分类）。

假设银行需要根据顾客的年龄、薪资、当前债务来决定是否给予信用卡，已知 5 个人获得信用卡时的相关信息如下：

	客户 1	客户 2	客户 3	客户 4	客户 5	自己
年龄	16	24	23	28	40	50
薪资（月）	0	5000	6000	5000	15000	12000
债务（万）	0	0	10	50	200	30
是否获批	否	是	是	否	是	？

请判断自己去该银行申请信用卡时能否获得。

1 输入变量 $X = [x_1, x_2, x_3] = [\text{年龄}, \text{薪资}, \text{债务}]$

2 权重 $W = [w_1, w_2, w_3]$ 偏置值为 b

3 激活函数选sigmoid

4 获批结果否为0，是为1

5 输出 $y = \text{sigmod}(w_1x_1 + w_2x_2 + w_3x_3 + b)$

6 手工尝试不同的参数，比较误差值

7 机器学习求得

8 结局：当输出 $y < 0.5$ ，未获批，否则获批。

- 要求：
- 1、MO平台上能跑通代码，并能阅读代码，理解每句代码的意思
 - 2、能迁移到本地在pyCharm中跑通
 - 3、能做些简单的修改

感知机案例-线性回归



例 8-2：用感知机模型实现预测问题（线性回归）。

假设一个公司的销售人员每个月的薪水由底薪+销售提成组成，已知该销售人员前 6 个月的销售
额与薪水数据如下：

	1 月	2 月	3 月	4 月	5 月	6 月	7 月
销售额（万 元）	1.2	1.5	3.2	2.7	5.3	3.3	4.1
薪水（万元）	0.36	0.375	0.48	0.435	0.724	0.465	?


如果第 7 个月的销售额为 12.5 万，请预测该销售员的该月能拿到多少薪水。

感知机案例-线性回归



解：(1) 薪水由底薪+销售额提成组成，即 $y = wx + b$ ，其中 x 为销售额， b 为底薪， w 为提成比例。

这是一个非常简化的感知机模型，因为求解的是线性回归问题，所以激活函数 $f(x) = x$ 。



(2) 求得的其中一个最优解为 $y = 0.086x + 0.226$ 。

(3) 当 $x = 4.1$ 时， $y = 0.5786$ 。

课后作业

思考：上述解法是税前的算法，如何预测税后的薪水？如果提成比例是分段提成的，又该如何预测

要求：用Python实现

重要结论：感知机模型可以实现所有的线性分类和线性回归问题。

感知机的局限



1969年，马文·明斯基出版了《感知机》一书，证明了感知机无法解决“异或问题”，给感知机模型直接宣判了“死刑”。

A	B	异或
0	0	0
0	1	1
1	0	1
1	1	0

异或问题







单隐含层MLP


多层感知器 (MLP)

- 多层感知器是罗森布拉特标准感知器的扩展。如果以神经元来计算层数，一个多层感知器至少包含三层：一个输入层，一个隐藏层和一个输出层。
- 数据通过输入层进入网络，乘以连接的权重入后输入到隐藏层节点。隐藏层节点将这些加权后的输入求和并经过一个非线性变换（称为激活函数）后送往输出层。



只有一个隐含层的叫浅层学习网络，隐含层大于一层的叫深度学习网络

单隐含层MLP



Learning representations by back-propagating errors

David E. Rumelhart*, Geoffrey E. Hinton†
& Ronald J. Williams*


* Institute for Cognitive Science, C-015, University of California,
San Diego, La Jolla, California 92093, USA

† Department of Computer Science, Carnegie-Mellon University,
Pittsburgh, Philadelphia 15213, USA

We describe a new learning procedure, back-propagation, for networks of neurone-like units. The procedure repeatedly adjusts the weights of the connections in the network so as to minimize a measure of the difference between the actual output vector of the net and the desired output vector. As a result of the weight adjustments, internal 'hidden' units which are not part of the input or output come to represent important features of the task domain, and the regularities in the task are captured by the interactions of these units. The ability to create useful new features distinguishes back-propagation from earlier, simpler methods such as the perceptron-convergence procedure¹.

- 1986年，戴维·鲁姆哈特、杰弗里·辛顿和罗纳德·威廉姆斯在《自然》杂志发表论文，提出了一种称为“**反向传播算法（BP算法）**”的训练方法，使得**多层神经网络训练成为可能**。
- 多层神经网络解决了感知器模型只能处理线性可分问题的缺陷，使神经网络真正成为强大的建模工具。

损失函数-试错中学习



试图建立起联接关系的两个神经元

差异的表示方法有多种，如用方差表示输出 y_{pk} 与目标输出 t_{pk} 的差异：

$$E = \frac{1}{2} \sum_p \sum_k (t_{pk} - y_{pk})^2 \quad \text{或} \quad E_p = \frac{1}{2} \sum_k (t_{pk} - y_{pk})^2$$

E 和 E_p 的区别：

前者对所有的样本进行误差求和
后者是对单个样本的误差进行求和




图 单隐含层MLP拓扑结构

常用损失函数



(1) 回归损失函数，用于衡量回归系统的误差，常见的有如下几种：

均方误差 (mean_squared_error)

$$MSE = \frac{1}{N} \sum_{i=1}^N (T_i - Y_i)^2$$

平均绝对误差 (mean_absolute_error)

$$MAE = \frac{1}{N} \sum_{i=1}^N |T_i - Y_i|$$

平均绝对百分比误差 (mean_absolute_percentage_error)

$$MAPE = \frac{1}{N} \sum_{i=1}^N \left| \frac{Y_i - T_i}{Y_i} \right| \times 100$$

均方根对数误差 (mean_squared_logarithmic_error)

$$MSLE = \frac{1}{N} \sum_{i=1}^N [\log(T_i + 1) - \log(Y_i + 1)]^2$$

(2) 分类损失函数，用于衡量分类系统的误差

二进制交叉熵 (binary_crossentropy)：用于二分类问题，对应的激活函数是sigmoid

$$Loss = -\frac{1}{N} \sum_{i=1}^N [Y_i \times \log T_i + (1 - Y_i) \times (1 - T_i)]$$

多分类交叉熵 (categorical_crossentropy)：用于多分类问题，对应的激活函数是softmax

$$Loss = -\frac{1}{N} \sum_{i=1}^N Y_i \times \log T_i$$

在开发具体的应用时，也可以根据自己要求设计损失函数。损失函数的设计也是非常重要的技术创新领域，具有很大的挑战性，但是对提高系统的性能、模型训练的质量都是非常重要的。

“没有免费的午餐” 定律



BP算法

误差反向传播算法-BP



- 反向传播算法是一种常见的人工神经网络学习算法，特别适用于多层前馈神经网络的训练。该算法由学习过程中的信号正向传播与误差的反向传播两个过程组成。






图 BP算法流程图

BP算法原理



正向传播



隐含层: 第 j 个神经元的输入为: $net_j = \sum w_{ji}x_i + b$ b 为偏置

输出为: $a_j = f(net_j)$

激活函数 f 为Sigmoid函数


$$a_j = \frac{1}{1 + e^{-net_j}}$$

输出层: 第 k 个神经元的输入为: $net_k = \sum_j w_{kj}x_j + b$

输出为: $a_k = f(net_k)$

反向传播

目标函数的输出值与期望输出不相符时，将输出误差以某种形式通过隐层向输入层逐层反传，在反传过程中，将误差分摊给各层的所有单元，获得各层单元的误差信号，算法根据这些误差值来调整连接权值，这种调整的目标是使得目标函数的输出值不断减小，直到达到设计预期



梯度下降法



BP算法的特点

- (1) 自适应、自主学习：BP算法能够根据预设的参数更新规则，不断地调整神经网络中的参数，以达到最符合期望的输出。
- (2) 较强的非线性映射能力：由于神经网络中的激活函数都是非线性的，因此BP算法能够处理复杂的非线性问题。
- (3) 严谨的推导过程：误差的反向传播过程采用的是已经非常成熟的链式法则，其推导过程严谨且科学。
- (4) 较强的泛化能力：在训练结束后，BP算法可以利用从训练数据中学到的知识解决新的问题。


BP算法的局限性

- (1) 易陷入局部最小值：由于BP算法采用的是梯度下降法，容易陷入局部极小值而得不到全局最优解。
- (2) 收敛速度慢：由于神经网络中的参数众多，每次迭代都需要更新大量的权值和阈值，导致收敛速度较慢。
- (3) 隐节点选取缺乏理论指导：传统方法需要不断地设置隐含层节点数进行试凑，以确定最优的隐含层结构。
- (4) 学习新样本时可能遗忘旧样本：在训练过程中，学习新样本时可能会遗忘之前已经学习过的旧样本。


激活函数




激活函数的作用是通过非线性变换，使神经网络具备非线性特性，以解决一些非线性任务。



线性网络




非线性网络



Sigmoid

$$f(x) = \frac{1}{1 + e^{-x}}$$




特性:

- 1) 非线性
- 2) 在-3与3之间，优化比较明显
- 3) 在-3与3之外，优化不明显
- 4) 值域在0~1之间，是非对称算法，这意味着下一个神经元只能接受正值的输入

Tanh

$$f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$



特性:

- 1) 非线性
- 2) 在-3与3之间, 优化比较明显
- 3) 在-3与3之外, 优化不明显
- 4) 值域在-1~1之间, 是对称算法, 解决了Sigmoid的局限
- 5) 梯度比Sigmoid陡峭, 易形成梯度崩塌

Softmax

$$s_i = \frac{e^{x_i}}{\sum_j e^{x_j}}$$

Softmax是将一个包含任意实数的K维向量压缩（或称为“归一化”）成另一个K维的实数向量，其中每一个元素的范围都在(0, 1)之间，并且所有元素的和为1。因此，Softmax的输出可以被解释为概率分布，其中每个概率对应着输入向量中对应元素属于某个类别的概率。

用途：应用最为广泛的一个激活函数分类器，一般用于最后一层，输出分类的概率结果，实现神经网络的分类，如：手写数字识别、物体分类、蛋白质结构分类、气象预测等应用

例 8-5：对于输入 $X = [2, 0.7, -1.5, -0.9]$ ，计算 Softmax 输出。

解：

$$sum = \sum_j e^{x_j} = e^2 + e^{0.7} + e^{-1.5} + e^{-0.9} = 10.03$$

$$S_1 = e^{x_1} / sum = e^2 / 10.03 = 0.74$$


$$S_2 = e^{x_2} / sum = e^{0.7} / 10.03 = 0.20$$

$$S_3 = e^{x_3} / sum = e^{-1.5} / 10.03 = 0.02$$

$$S_4 = e^{x_4} / sum = e^{-0.9} / 10.03 = 0.04$$

ReLU

$$f(x) = \max(0, x)$$




特性：

- 1) 非线性
- 2) 不会同时激活所有神经元
- 3) 计算速度快
- 4) 有趋于0的梯度

ReLU是目前隐含层中最为常用的损失函数

ELU

$$f_i(a_i) \begin{cases} x & \text{if } x > 0 \\ \alpha(e^x - 1) & \text{if } x \leq 0 \end{cases}$$




特性：

- 1) 非线性
- 2) 计算速度快（特指收敛速度快）
- 3) 参数可调，可控制负数部分的表现
- 4) 与ReLU相比，没有死亡神经元

缺点：负数部分计算较慢

实战案例-MNIST手写体数字识别



Mnist数据集是学习深度学习最常用到的数据集。

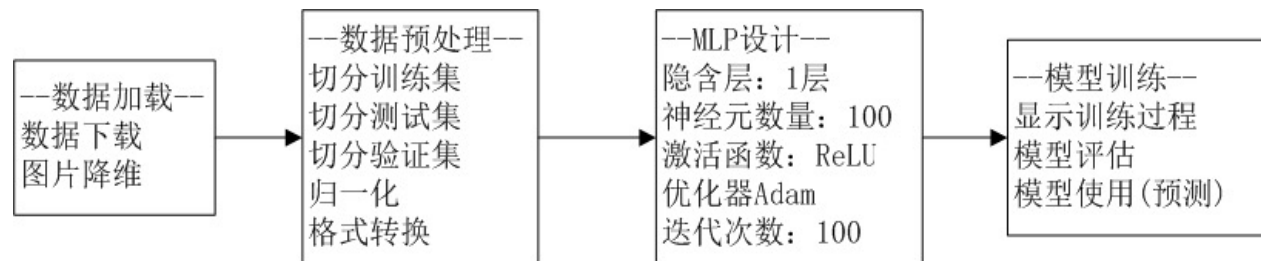
训练集：60000张

测试集：10000张

采集人数：250人（高中生，工作人员）

分辨率：28*28（784像素）

数据集的下载地址：<http://yann.lecun.com/exdb/mnist/>



sklearn进行MLP训练的基本流程

开放的科学机器学习平台：OpenML (Open Machine Learning)

- 要求：
- 1、MO平台上能跑通代码，并能阅读代码，理解每句代码的意思
 - 2、能迁移到本地在pyCharm中跑通
 - 3、能做些简单的修改

