




浙江大学
ZHEJIANG UNIVERSITY



自然语言处理建模

计算机学院 陈建海

2024年12月2日



课程二维码

本课件仅供教学使用，未经许可不得转载





提纲

- 1 NLP概述
- 2 NLP技术基础
- 3 经典NLP模型
- 4 西游记人物关系分析



NLP概述

目录

- 自然语言处理简介
- 自然语言处理技术基础
- 自然语言处理核心技术
- 自然语言处理前沿研究
- 自然语言处理挑战与未来趋势


contents

01

自然语言处理简介



自然语言处理定义



01

自然语言处理（NLP）是人工智能领域的一个分支，研究如何使计算机理解和生成人类自然语言文本。



02

NLP涉及语言学、计算机科学、心理学等多个学科领域，旨在通过算法和模型实现人类与计算机之间的自然语言交互。



自然语言处理发展历程

01



早期阶段

以规则为基础的方法，通过手工编写规则实现简单的自然语言处理任务。


02



统计学习方法

基于大规模语料库的统计学习方法逐渐成为主流，如隐马尔可夫模型、条件随机场等。

03



深度学习时代

深度学习技术的兴起为NLP领域带来了革命性突破，如循环神经网络、Transformer等模型在NLP任务中取得了显著成果。



自然语言处理应用领域

机器翻译

将一种自然语言文本自动翻译成另一种自然语言文本，如谷歌翻译、有道翻译等。

语音识别与合成

将人类语音转换为文本或将文本转换为人类语音，用于语音助手、无障碍技术等领域。

情感分析

识别和分析文本中的情感倾向和情感表达，用于产品评论、社交媒体分析等领域。

智能问答

根据用户提出的问题，自动检索相关信息并生成简洁明了的回答，如Siri、Alexa等智能助手。

文本摘要

将长篇文本自动缩减为简短的摘要，便于用户快速了解文本主要内容。



02

自然语言处理技术基础

词汇分析技术

分词技术

将连续的自然语言文本切分为独立的词汇单元，是中文自然语言处理的基础任务之一。



词性标注

为每个词汇单元分配一个词性标签，如名词、动词、形容词等，有助于理解词汇在句子中的角色。



命名实体识别

识别文本中具有特定意义的实体，如人名、地名、机构名等，对于信息抽取和问答系统具有重要意义。



句法分析技术



短语结构分析

识别句子中短语的构成及短语之间的关系，如主谓关系、动宾关系等。



依存句法分析

通过分析句子中词汇之间的依存关系，揭示句子的结构，有助于理解句子的含义。



深层句法分析

探究句子中更深层次的句法结构，如句子中的逻辑关系和语义角色等。



语义理解技术

词义消歧

确定多义词在特定上下文中的具体含义，是自然语言处理中的一个重要问题。

情感分析


识别和分析文本中的情感倾向和情感表达，对于舆情分析和产品评价具有重要意义。

问答系统

根据用户的问题，自动检索相关信息并生成简洁明了的回答，是自然语言处理技术的综合应用。

文本生成与摘要

基于特定主题或要求，生成结构合理、语义通顺的文本，或者将长文本浓缩为简短的摘要，便于快速浏览和理解。



03


自然语言处理核心技术



机器翻译技术

基于规则的翻译方法

利用语言学知识，手动编写翻译规则进行翻译。



神经网络机器翻译方法

利用深度学习技术，构建神经网络模型进行翻译，具有更高的翻译质量和效率。

统计机器翻译方法

基于大规模语料库，通过统计学习算法自动学习翻译模型。





信息抽取技术



命名实体识别

识别文本中的实体名词，如人名、地名、机构名等。



关系抽取

从文本中抽取出实体之间的关系，构建知识图谱。



事件抽取

识别文本中的事件及其参与者、时间、地点等要素，用于事件分析和预警。

情感分析技术



词典匹配法

基于情感词典，通过匹配文本中的情感词汇进行情感分析。

机器学习法

利用机器学习算法，对大量标注好的情感文本进行训练，构建情感分类器。

深度学习法

利用深度学习技术，构建神经网络模型进行情感分析，具有更高的准确率和泛化能力。

04

自然语言处理前沿研究

深度学习在NLP中应用

01

词向量表示

通过神经网络训练语言模型，将单词表示为高维向量，捕捉语义和语法信息。

02

循环神经网络 (RNN)

处理序列数据，如文本，通过捕捉历史信息来预测未来。

03

长短期记忆网络 (LST...

解决RNN梯度消失问题，更好地捕捉长期依赖关系。

04

注意力机制

模仿人类注意力，使模型能够关注文本中的重要部分。

05

Transformer...

基于注意力机制，实现并行计算，提高训练速度和性能。

知识图谱与NLP结合

知识图谱构建

从文本中抽取实体、关系等结构化信息，构建知识图谱。

知识图谱嵌入

将知识图谱中的实体和关系嵌入到低维向量空间，便于计算和推理。

基于知识图谱的问答系统

利用图谱中的结构化信息，回答涉及复杂推理的问题。

文本生成与知识图谱

结合知识图谱中的信息，生成更加丰富、准确的文本。






对话系统与NLP关系

对话系统架构

包括自然语言理解、对话管理、自然语言生成等模块，NLP技术贯穿始终。



意图识别与槽位填充

识别用户对话中的意图和关键信息，为对话系统提供决策支持。

对话历史追踪

利用NLP技术捕捉对话历史中的关键信息，实现上下文相关的对话。



情感分析与对话系统

识别用户情感，调整对话策略，提高用户体验。



05

自然语言处理挑战与未来趋势



当前面临的主要挑战

数据稀疏性问题

自然语言处理中常常面临数据稀疏性问题，即某些语言现象在语料库中出现的频率非常低，导致模型难以充分学习。

多义词和歧义消解

自然语言中存在大量的多义词和歧义现象，如何准确地理解和消解这些歧义是NLP的重要挑战。

跨语言处理

不同语言之间存在显著的差异，如何有效地进行跨语言处理是NLP领域的一个重要研究方向。

复杂语言现象建模

自然语言中存在许多复杂的语言现象，如隐喻、比喻、讽刺等，如何准确地建模这些语言现象是NLP的难题之一。



未来发展趋势预测

随着深度学习技术的不断发展，未来NLP领域将更加注重深度学习技术的融合和创新，如Transformer、BERT等模型的改进和应用。

深度学习技术融合

随着全球化进程的加速，跨语言迁移学习将成为NLP领域的重要研究方向，旨在实现不同语言之间的知识迁移和共享。

多模态数据处理

未来NLP将更加注重多模态数据的处理和分析，如结合文本、图像、音频等多种信息进行综合理解和分析。

个性化和情感计算

随着人们对个性化和情感计算的需求不断增加，未来NLP将更加注重个性化和情感计算技术的研发和应用。

跨语言迁移学习





行业应用前景展望

智能客服

利用NLP技术实现智能客服，能够自动回答用户的问题和解决用户的问题，提高客户满意度和效率。

智能翻译

利用NLP技术实现智能翻译，能够快速准确地将一种语言翻译成另一种语言，促进跨语言交流和合作。



情感分析


利用NLP技术实现情感分析，能够自动识别和分析文本中的情感倾向和情感表达，为企业和政府机构提供舆情分析和决策支持。

智能写作

利用NLP技术实现智能写作，能够自动生成高质量的文本内容，为新闻媒体、广告营销等领域提供有力的支持。

图灵测试：

多名评委在隔开的情况下，通过设备向一个机器人和一名人类随意提问。
多次问答后，若超过30%的人不能确定被测者是人还是机器，那么，该机具备人类智能。




图灵测试中对机器智能的定义，就是机器能在与人类裁判的**对话**中，躲过裁判，让他认为这是真人与他在对话。

自然语言处理的准确性是机器具备智能的必要条件

NLP起源



孔子三千弟子，采用雅言



秦始皇统一文字



盟军之间合作需要翻译

NLP案例



百度智能音箱



<http://chatyy.jlrkwl.cn/>

大语言模型




智海-三乐 @sanle Bot 下午1点21分
深度学习是一种基于人工神经网络的机器学习方法，可以用来处理复杂的模式识别和分类问题。它通过利用多层神经网络来提取数据的抽象特征，从而使模型能够自主学习和改进。深度学习已经被广泛应用于计算机视觉、自然语言处理、语音识别、推荐系统等领域，并取得了一系列令人瞩目的成果。

剩余提问次数：13次，【智海-三乐】额度与【GPT 助手】共享，增加额度



AI助教



请写出200字的摘要



使用: 阅读助手


这份文件介绍了一种名为BiomedGPT的通用型视觉-语言基础模型，用于执行多样的生物医学任务。该模型是首个开源且轻量级的，能够处理文本和视觉信息，实现了16个生物医学任务中的最优结果。通过跨学科数据训练和多任务微调，BiomedGPT展现出强大的迁移学习能力。研究强调了其在实际诊断和 workflows 效率提升方面的潜力。与商业模型Med-PaLM M相比，BiomedGPT更加透明且参数更少。该模型的设计和评估展示了通用型生物医学AI模型的前景。

文献阅读


由文心大模型 3.5 生成




翻译机




基于规则算法




统计语言模型




序列生成模型




预训练-微调模型



基于语法



- [HED] 表示核心关系，即句子的中心词是“去”，这是一个动词，表示行为动作。
- [ADV] 表示状中关系，即“今天”作为状语修饰动词“去”，说明动作发生的时间。
- [SBV] 表示主谓关系，即“我”是主语，是执行“去”这个动作的主体。
- [VOB] 表示动宾关系，即“北京”是宾语，是“去”这个动作的目的地。



WordNet项目 <https://wordnet.princeton.edu/>

统计语言模型（也是一种规则）



熟读唐诗三百首，不会作诗也会吟

生成式模型

统计某个条件（字、连续的词）后出现的概率进行生成——**MAX(P(O|Q))**

条件Q为“春”，词汇的概率

["天"、"风"、"色"、"秋"、。 。 。 。 。]=[0.31, 0.21, 0.15, 0.18, 。 。 。 。 。]

问题：样本要足够大；不顾上下文

区分式模型 判别式模型

朴素贝叶斯公式

$$P(A|B) = \frac{P(B|A) \times P(A)}{P(B)}$$

优点：有限样本


预测：天行健，君子以自（？）不息

1. “***自” 之后出现什么字概率最大？ B= “***自”
2. 通过语料统计所有字的字频（先验概率），获得P(A)、P(B)，A=[强、己、我、牛、人、.....]
3. 通过语料计算所有AB同时出现的条件概率P(B|A)，即P(自|强)
4. 计算所有A的P(A|B)，即P(强|自)、P(己|自)、P(学|自).....
5. 概率从大到小排序
6. 朴素：假设A和B是独立事件


序列生成模型




输入序列 → 编码器 → 处理器 → 解码器 → 输出序列



Transformer



RNN



LSTM

预训练-微调大模型




图 预训练-微调的二种模式



NLP技术基础

分词



Token: 令牌, 可以是一个字, 也可以是一个词, 或者是一个字母, 甚至是一个字节, 要看具体的情况。本质上, 一个 “Token” 就是通过分词技术 (工具) 将一句话分割成的最小单位, 是一个特定的自然语言处理模型能处理的最基本元素。

“黄山落叶松叶落山黄”

- **按字分** “黄-山-落-叶-松-叶-落-山-黄” 词汇表5个token, 句子9个token
- **按词分** “黄山-落叶松-叶-落-山-黄” 词汇表6个token, 句子6个token

“I like to read this **book** about
books that I like”
如何分词?

《通用规范汉字表》包含了8105个汉字
《汉语大字典》收录的汉字5万多个
《中华字海》收录87000左右汉字
《牛津辞典》收录60万以上英文单词

分词需在词汇表大小和语料大小之间取得平衡, 也是模型成败最关键一步, 开源模型都自带分词工具和词汇表

词向量和词嵌入



词向量就是词的特征分布，是NLP模型层与层之间进行信息传递的数据形式

词向量和词嵌入是指的同一个东西，区别在于词向量是指数字编码技术，词嵌入是指NLP网络之间的数据存在形式

	水果	公司	手机	粮食
$R_{\text{橘子}}$	$r_{\text{橘子,水果}}$	$r_{\text{橘子,公司}}$	$r_{\text{橘子,手机}}$	$r_{\text{橘子,粮食}}$
$R_{\text{香蕉}}$	$r_{\text{香蕉,水果}}$	$r_{\text{香蕉,公司}}$	$r_{\text{香蕉,手机}}$	$r_{\text{香蕉,粮食}}$
$R_{\text{苹果}}$	$r_{\text{苹果,水果}}$	$r_{\text{苹果,公司}}$	$r_{\text{苹果,手机}}$	$r_{\text{苹果,粮食}}$
$R_{\text{小米}}$	$r_{\text{小米,水果}}$	$r_{\text{小米,公司}}$	$r_{\text{小米,手机}}$	$r_{\text{小米,粮食}}$
$R_{\text{华为}}$	$r_{\text{华为,水果}}$	$r_{\text{华为,公司}}$	$r_{\text{华为,手机}}$	$r_{\text{华为,粮食}}$

学习后



	水果	公司	手机	粮食
$R_{\text{橘子}}$	0.92	0.23	0.02	0.19
$R_{\text{香蕉}}$	0.95	0.13	0.09	0.25
$R_{\text{苹果}}$	0.96	0.77	0.85	0.15
$R_{\text{小米}}$	0.08	0.81	0.98	0.87
$R_{\text{华为}}$	0.02	0.93	0.95	0.01



也是词向量!

数学形式

$$\begin{bmatrix} V_1 \\ \vdots \\ V_n \end{bmatrix} = \begin{bmatrix} V_{11} & \cdots & V_{1m} \\ \vdots & \ddots & \vdots \\ V_{n1} & \cdots & V_{nm} \end{bmatrix}$$

词表大小为n个Token，特征值数量为m

句子的独热码表示



黄	[1,0,0,0,0]
山	[0,1,0,0,0]
落	[0,0,1,0,0]
叶	[0,0,0,1,0]
松	[0,0,0,0,1]
叶	[0,0,0,1,0]
落	[0,0,1,0,0]
山	[0,1,0,0,0]
黄	[1,0,0,0,0]

方式一：二维的稀疏矩阵

“黄山落叶松叶落山黄”


[2,2,2,2,1]

方式二：一维的稠密矩阵

文本相似度



有了词向量的表示，就可以非常容易的计算文本相似度，一般地，语义相近的词在向量空间上具有相近的位置。



将每个词映射到多维空间中的一个点

余弦相似度

设两个文本的向量为 A 和 B ，那么 A 、 B 的余弦相似度计算公式如下：

$$\text{Cosine Similarity} = \cos \theta = \frac{A \cdot B}{\|A\| \|B\|}$$

$A \cdot B$ 表示向量 A 和 B 的点积, $\sum_{i,j} A_i \cdot B_j$ ($i = 1 \sim m$, $j = 1 \sim n$)

而 $\|A\| \|B\|$ 表示 A 的模和 B 的模乘积, $\sqrt{\sum_{i=1}^m (A_i)^2} \times \sqrt{\sum_{j=1}^n (B_j)^2}$

$$\begin{aligned} \cos(0^\circ) &= 1 \\ \cos(90^\circ) &= 0 \\ \cos(180^\circ) &= -1 \end{aligned}$$

欧式距离

$$d = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

距离越短，则两个文本越相似

Jaccard相似度

$$EJ(A, B) = \frac{A \cdot B}{\|A\|^2 + \|B\|^2 - A \cdot B}$$

其中， $A \cdot B$ 表示向量乘积， $\|A\|$ 和 $\|B\|$ 分别表示向量 A 和 B 的模。

狭义定义: $J(A, B) = \frac{|A \cap B|}{|A \cup B|}$

值越大，则两个文本越相似

例11-1: 根据上节的表2, 计算华为和苹果的余弦相似度 和 广义Jaccard相似度。

解: 根据表2可知, 令华为的词向量 $A = [0.02, 0.93, 0.95, 0.01]$, 苹果的词向量 $B = [0.96, 0.77, 0.85, 0.15]$

$$A \cdot B = 0.02 \times 0.96 + 0.93 \times 0.77 + 0.95 \times 0.85 + 0.01 \times 0.15 = 1.5443$$

$$\|A\| = \sqrt{0.02^2 + 0.93^2 + 0.95^2 + 0.01^2} = \sqrt{1.7679} = 1.3296$$

$$\|B\| = \sqrt{0.96^2 + 0.77^2 + 0.85^2 + 0.15^2} = \sqrt{2.2595} = 1.5032$$

$$\text{余弦相似度: } \cos \theta = \frac{A \cdot B}{\|A\| \|B\|} = 0.7727$$

$$\text{广义Jaccard相似度: } EJ(A, B) = \frac{A \cdot B}{\|A\|^2 + \|B\|^2 - A \cdot B} = \frac{1.5443}{1.7679 + 2.2595 - 1.5443} = 0.6219$$

	水果	公司	手机	粮食
$R_{\text{橘子}}$	0.92	0.23	0.02	0.19
$R_{\text{香蕉}}$	0.95	0.13	0.09	0.25
$R_{\text{苹果}}$	0.96	0.77	0.85	0.15
$R_{\text{小米}}$	0.08	0.81	0.98	0.87
$R_{\text{华为}}$	0.02	0.93	0.95	0.01

例11-2: 计算以下两个文本的Jaccard相似度, 文本1 “我爱北京天安门”, 文本2 “天安门雄伟壮阔让人不得不爱” (不考虑词频)。

解: 文本1的集合 $A = \{\text{我, 爱, 北, 京, 天, 安, 门}\}$

文本2的集合 $B = \{\text{天, 安, 门, 雄, 伟, 壮, 阔, 让, 人, 不, 得, 爱}\}$

$$A \cap B = \{\text{爱, 天, 安, 门}\}$$

$$A \cup B = \{\text{我, 爱, 北, 京, 天, 安, 门, 雄, 伟, 壮, 阔, 让, 人, 不, 得}\}$$

$$\text{Jaccard相似度: } J(A, B) = \frac{|A \cap B|}{|A \cup B|} = \frac{4}{15} = 0.2667$$



经典NLP模型

词袋模型



词袋模型（Bag of Words, 简称BoW）是自然语言处理和信息检索中的一种常用文本表示方法。它将文本表示为一个词的集合，忽略词语的上下文关系，只计算词语的出现频率和其他统计值。

The Bag of Words Representation

I love this movie! It's sweet, but with satirical humor. The dialogue is great and the adventure scenes are fun... It manages to be whimsical and romantic while laughing at the conventions of the fairy tale genre. I would recommend it to just about anyone. I've seen it several times, and I'm always happy to see it again whenever I have a friend who hasn't seen it yet!



it	6
I	5
the	4
to	3
and	3
seen	2
yet	1
would	1
whimsical	1
times	1
sweet	1
satirical	1
adventure	1
genre	1
fairy	1
humor	1
have	1
great	1
...	...

构建过程

- 1 分词:
- 2 构建词表: 每个词语对应着一个唯一的索引
- 3 计算词频: 统计每个词在文本中出现的频次
- 4 向量化: 文本表示为向量

用python构建以下2句话的词袋模型并计算相似度

句子1: 词袋模型是自然语言处理和信息检索中的一种常用文本表示方法。它将文本表示为一个词的集合，忽略词语的顺序和语法结构，只关注词语的出现频率或其他统计量。




句子2: 词袋模型是一种将文本数据转换为数值型向量的方法，其中文本被视为一个由词语组成的无序集合，每个词语的出现都被独立考虑，而不考虑其上下文或顺序。

问题: 不考虑词的次序, 比如GAI=AGI; 小红站在小明的右边=小明站在小红的右边

Word2Vec




假设这是一篇文章，有N (=3) 个句子，如何进行文本的分布式表示？



分析《西游记》的人物关系





THANKS