




浙江大学
ZHEJIANG UNIVERSITY



Attention is All You Need



自然语言处理建模 Transformer

计算机科学与技术学院 陈建海

2024年12月4日



课程二维码

本课件仅供教学使用，未经许可不得转载





提纲

- 1 概述
- 2 编码器
- 3 解码器
- 4 注意力机制
- 5 三种类型的模型



Transformer概述

Transformer概述



- **Transformer**是一种基于**注意力机制**的序列模型
- 最初由**Google**的研究团队提出并应用于**机器翻译任务**
- 与传统的循环神经网络 (RNN) 和卷积神经网络 (CNN) 不同
- **Transformer**仅使用**自注意力机制** (self-attention) 来**处理输入序列和输出序列**, 可以**并行计算**, 极大地提高了**计算效率**

Attention Is All You Need

(NIPS 2017)

Ashish Vaswani*
Google Brain
avaswani@google.com

Noam Shazeer*
Google Brain
noam@google.com

Niki Parmar*
Google Research
nikip@google.com

Jakob Uszkoreit*
Google Research
usz@google.com

Llion Jones*
Google Research
llion@google.com

Aidan N. Gomez* †
University of Toronto
aidan@cs.toronto.edu

Łukasz Kaiser*
Google Brain
lukaszkaizer@google.com

Illia Polosukhin* ‡
illia.polosukhin@gmail.com

Abstract


The dominant sequence transduction models are based on complex recurrent or convolutional neural networks that include an encoder and a decoder. The best performing models also connect the encoder and decoder through an attention mechanism. We propose a new simple network architecture, the Transformer, based solely on attention mechanisms, dispensing with recurrence and convolutions entirely. Experiments on two machine translation tasks show these models to

1、序列到序列的编码器-解码器，自回归语言生成技术

用大语言模型模仿《满江红》

2、注意力机制


第十二卦：否卦（否：否之匪人，不利君子贞，大往小来。）




乾卦



总体结构




Transformer总体结构



与RNN的比较


LLM可视化网站: <https://bbycroft.net/llm>






编码器

编码器——输入向量




单个编码器层的展开





嵌入层内部实现原理

- (1) 分词: $S=[\text{我, 在, 学, 人, 工, 智, 能}]$
- (2) 增加位置序列 $P=[1, 2, 3, 4, 5, 6, 7]$
- (3) 编码: 在嵌入层网络, 完成对S和P的编码工作, 然后将S与P进行拼接, 输出向量X。




单个编码器层的展开




跨层和归一化

编码器-逐位置前馈网络



单个编码器层的展开




逐位置前馈网络：是一个两层的前馈神经网络，每个位置的词向量都独立地经过这个网络进行变换，而不是通常的将多维输入向量平铺展开成一维的向量。在上图中展示的是采用两个**一维卷积网络**

一维卷积网络：kernel_size=1

```
import torch.nn as nn
nn.Conv1d
```



解码器



单个解码器层的展开

关于解码器的输入:

(1) 编码器的输入+解码器的输出

比如: 白日依山尽→黄河入海流

输入=白日依山尽

输出=黄河入海流

编码器的输入=白日依山尽黄河入海流

(2) 填充掩码

输出采用自回归算法, 为防止看到未来数据, 所以需要增加一个掩码操作, 把当前位置之后的数据掩盖掉, 解码器边生成边向右移动, 直到出现终止条件, 比如:

第一步: [我<pad><pad><pad><pad><pad><pad>]



第二步: [我在<pad><pad><pad><pad><pad>]

.....

最后一步: [我在学人工智能]

<pad>就是一个掩码符, 计算机在处理的时候会忽略<pad>位置的信息。


解码器-微调大模型





多头注意力机制

自注意力机制



线性变换

在注意力机制中， Q (Query, 查询)、 K (Key, 键) 和 V (Value, 值) 是三个关键概念：

Q ：指当前需要关注或查询的信息点，用于与 K 进行相似度计算，以确定哪些键（及其对应的值）是重要的，并据此分配注意力权重。

K ：指输入数据中的各个部分或特征，用于与 Q 进行匹配，以确定哪些部分与当前查询最为相关， K 的得分将用于计算注意力权重，进而决定从 V 中提取多少信息。

V ：指实际被加权求和以生成输出的参数，它包含了输入数据中的具体信息。 V 根据注意力权重进行加权求和，以生成最终的注意力输出。

延续前面2节的案例，我们从自注意力机制、多头自注意力机制二个方面来进一步了解Transformer的工作机制。

(1) 线性变换

$$Q = XW^Q$$

$$K = XW^K$$

$$V = XW^V$$

(2) 计算注意力分数

$$score = QK^T$$

$score$ 是表示 Q 和 K 之间的相似度

(3) 归一化注意力分数


$$attention_weigh = \text{softmax} \left(\frac{score}{\sqrt{D}} \right)$$

$D=512$

(4) 最终注意力分数

$$Z = attention_weigh \cdot V \text{ (加权和点积)}$$

多头自注意力机制



多头注意力即将 Q 、 K 、 V 分为 N 个头，每个头使用不同的权重参数进行自注意力计算，所有这些头的注意力分数会最终拼接起来，产生最终的多头注意力分数。 N 通常设为8。本例为表述方便，设 $N=2$ 。

多头注意力机制是在自注意力机制的基础上扩展的

(1) 将输入在多个子空间里捕获多种特征，每一个头关注某一个特征，如词性、成分、词义、位置、关键词

(2) 可进行并行处理，加快训练。



三种模型

BERT




BERT系列: **仅采用编码器**结构而无解码器, google 2018年提出

BERT强项: 语义的理解能力, 通过注意力机制, 可同时考虑单词的上下文信息
多任务训练方式

BERT弱项: 自然语言生成能力。因此需要搭配其他语言模型或进行微调

BERT应用: 阅读理解、完形填空、命名实体识别、QA、机器翻译、情感分类等




BERT的一种输入编码方式



GPT系列：仅采用解码器结构而无编码器，OpenAI 2018年提出
GPT强项：自然语言生成能力，通过自回归技术生成对话
GPT弱项：语义的理解能力，因此需要搭配其他语言模型或进行微调。
BERT应用：内容生成、问答系统、机器翻译、代码补全等

可视化网站：
<https://bbycroft.net/llm>

主要模型	发布时间	参数规模	特点
GPT-1	2018年	1.17亿	GPT系列的首个模型，是一个单向语言模型，即只能根据上文来生成接下来的文本
GPT-2	2019年	15亿	能够生成更长的文本段落，甚至能够编故事和生成假新闻
GPT-3	2020年	1750亿	可以在没有或仅有少量监督训练的情况下，完成多种NLP任务，如文本自动补全、将网页描述转换为相应代码、模仿人类叙事等。GPT-3的出现标志着语言模型的发展进入了一个新的阶段，其生成的文本质量已经接近人类水平。
GPT-4	2023年	1.8万亿	是一个大型多模态模型，支持图像和文本输入，再输出文本回复。GPT-4的推出进一步扩展了GPT系列模型的应用范围和能力边界。



自回归工作方式示意图

工作方式1：贪婪采样 工作方式2：多项式采样

T5-Text-To-Text Transfer Transformer



T5系列：同时**采用解码器和编码器**，Google 2019年提出

T5强项：将NLP任务统一到一个框架（序列到序列）下进行训练，能力比较平衡

T5弱项：参数规模小，模型结构复杂，计算资源需求高，特定任务表现差。

T5-base: 6000万



T5-base: 2.2亿

T5-large: 7.7亿


T5-3B: 30亿

T5-11B: 110亿


T5应用：翻译、摘要、问答等




编-解码模式



通用语言模式



前缀语言模式



THANKS