



浙江大学
ZHEJIANG UNIVERSITY



期末复习

计算机学院 陈建海

2024年12月23日



课程二维码

本课件仅供教学使用，未经许可不得转载






编码器

特征向量



特征向量



特征向量




特征向量

解码器



深度学习概览




- 1、多层感知机 (MLP)
- 2、卷积神经网络 (CNN)
- 3、循环神经网络 (RNN)
- 4、Transformer
- 5、扩散模型 (Diffusion)

深度学习 (Deep Learning, DL) 是机器学习的一个子集，它使用**多层人工神经网络**来精准完成诸如物体检测、语音识别、语言翻译等任务。其基本思想是通过构建多层网络，对目标进行多层表示，以期通过**多层的高层次特征**来表示数据的抽象语义信息，从而获得更好的**特征鲁棒性**。

特征

多层网络结构：由多层神经元组成，包括输入层、隐藏层和输出层。这些层之间通过权重和偏置进行连接，形成复杂的网络结构。





自动特征提取：自动从原始数据中提取有用的特征，无需人工设计特征工程。

非线性激活函数：深度学习模型中通常使用非线性激活函数（如ReLU、sigmoid等），使得模型能够学习复杂的非线性关系。




大规模数据处理能力：借助现代计算技术和大数据资源，深度学习模型能够处理大规模数据集，提高模型的准确性和泛化能力。

人眼识别物体的基本过程



神经元的“**全或无**”现象：只有当外来刺激有足够大的强度，才能引起神经元细胞的兴奋并产生动作电位，但再增加刺激强度并不会导致动作电位的幅度发生变化。神经元细胞产生的动作电位沿着细胞膜向周围传播，传播的范围和距离也不会随刺激强度的不同而不同。

感知机模型



输入 X 可以是一个任意维度 n 的向量 $X = [x_1, x_2, \dots, x_n]$, W 是 X 的权重向量, $W = [w_1, w_2, \dots, w_n]$, 网络 $\sum = WX^T + b$ 完成线性变换。 f 是激活函数, 完成非线性变换。

要求：根据图写出输出 Y 的公式（形式化表示）

感知机案例-分类




例 8-1：用感知机模型设计二分类问题（线性分类）。

假设银行需要根据顾客的年龄、薪资、当前债务来决定是否给予信用卡，已知 5 个人获得信用卡时的相关信息如下：

	客户 1	客户 2	客户 3	客户 4	客户 5	自己
年龄	16	24	23	28	40	50
薪资（月）	0	5000	6000	5000	15000	12000
债务（万）	0	0	10	50	200	30
是否获批	否	是	是	否	是	?

请判断自己去该银行申请信用卡时能否获得。



1 输入变量 $X = [x_1, x_2, x_3] = [\text{年龄}, \text{薪资}, \text{债务}]$

2 权重 $W = [w_1, w_2, w_3]$ 偏置值为 b

3 激活函数选sigmoid

4 获批结果否为0，是为1

5 输出 $y = \text{sigmod}(w_1x_1 + w_2x_2 + w_3x_3 + b)$



6 手工尝试不同的参数，比较误差值

7 机器学习求得

8 结局：当输出 $y < 0.5$ ，未获批，否则获批。

多层感知机 (MLP)

- 多层感知机是罗森布拉特标准感知器的扩展。如果以神经元来计算层数，一个多层感知器至少包含三层：一个输入层，一个隐藏层和一个输出层。
- 数据通过输入层进入网络，乘以连接的权重后输入到隐藏层节点。隐藏层节点将这些加权后的输入求和并经过一个非线性变换（称为激活函数）后送往输出层。



只有一个隐含层的叫浅层学习网络，隐含层大于一层的叫深度学习网络

常用损失函数



(1) 回归损失函数，用于衡量回归系统的误差，常见的有如下几种：

均方误差 (mean_squared_error)

$$MSE = \frac{1}{N} \sum_{i=1}^N (T_i - Y_i)^2$$

平均绝对误差 (mean_absolute_error)

$$MAE = \frac{1}{N} \sum_{i=1}^N |T_i - Y_i|$$

平均绝对百分比误差 (mean_absolute_percentage_error)

$$MAPE = \frac{1}{N} \sum_{i=1}^N \left| \frac{Y_i - T_i}{Y_i} \right| \times 100$$

均方根对数误差 (mean_squared_logarithmic_error)

$$MSLE = \frac{1}{N} \sum_{i=1}^N [\log(T_i + 1) - \log(Y_i + 1)]^2$$

(2) 分类损失函数，用于衡量分类系统的误差

二进制交叉熵 (binary_crossentropy)：用于二分类问题，对应的激活函数是sigmoid

$$Loss = -\frac{1}{N} \sum_{i=1}^N [Y_i \times \log T_i + (1 - Y_i) \times (1 - T_i)]$$

多分类交叉熵 (categorical_crossentropy)：用于多分类问题，对应的激活函数是softmax

$$Loss = -\frac{1}{N} \sum_{i=1}^N Y_i \times \log T_i$$

在开发具体的应用时，也可以根据自己要求设计损失函数。损失函数的设计也是非常重要的技术创新领域，具有很大的挑战性，但是对提高系统的性能、模型训练的质量都是非常重要的。

“没有免费的午餐” 定律

误差反向传播算法-BP



- 反向传播算法是一种常见的人工神经网络学习算法，特别适用于多层前馈神经网络的训练。该算法由学习过程中的信号正向传播与误差的反向传播两个过程组成。





图 BP算法流程图




$$Y' = wx + b$$

$$\text{Loss} = \frac{1}{2} (Y' - Y)^2 = \frac{1}{2} (wx + b - Y)^2$$

$$\Delta w = -\alpha \frac{\partial \text{Loss}}{\partial w} = -\alpha (wx + b - Y)(x) = -\alpha x(Y' - Y)$$

$$w + \Delta w \rightarrow W$$



$$Y' = w_1x_1 + w_2x_2 + b$$

$$\text{Loss} = \frac{1}{2} (Y' - Y)^2 = \frac{1}{2} (w_1x_1 + w_2x_2 + b - Y)^2$$

$$\Delta w_1 = -\alpha \frac{\partial \text{Loss}}{\partial w_1} = -\alpha (w_1x_1 + w_2x_2 + b - Y)(x_1) = -\alpha x_1(Y' - Y)$$

$$\Delta w_2 = -\alpha \frac{\partial \text{Loss}}{\partial w_2} = -\alpha (w_1x_1 + w_2x_2 + b - Y)(x_2) = -\alpha x_2(Y' - Y)$$

$$w_1 + \Delta w_1 \rightarrow W_1 \quad w_2 + \Delta w_2 \rightarrow W_2$$



BP算法的特点


- (1) 自适应、自主学习：BP算法能够根据预设的参数更新规则，不断地调整神经网络中的参数，以达到最符合期望的输出。
- (2) 较强的非线性映射能力：由于神经网络中的激活函数都是非线性的，因此BP算法能够处理复杂的非线性问题。
- (3) 严谨的推导过程：误差的反向传播过程采用的是已经非常成熟的链式法则，其推导过程严谨且科学。
- (4) 较强的泛化能力：在训练结束后，BP算法可以利用从训练数据中学到的知识解决新的问题。

BP算法的局限性

- (1) 易陷入局部最小值：由于BP算法采用的是梯度下降法，容易陷入局部极小值而得不到全局最优解。
- (2) 收敛速度慢：由于神经网络中的参数众多，每次迭代都需要更新大量的权值和阈值，导致收敛速度较慢。
- (3) 隐节点选取缺乏理论指导：传统方法需要不断地设置隐含层节点数进行试凑，以确定最优的隐含层结构。
- (4) 学习新样本时可能遗忘旧样本：在训练过程中，学习新样本时可能会遗忘之前已经学习过的旧样本。

Sigmoid

$$f(x) = \frac{1}{1 + e^{-x}}$$




特性:

- 1) 非线性
- 2) 在-3与3之间, 优化比较明显
- 3) 在-3与3之外, 优化不明显
- 4) 值域在0~1之间, 是非对称算法, 这意味着下一个神经元只能接受正值的输入

ReLU

$$f(x) = \max(0, x)$$



特性:

- 1) 非线性
- 2) 不会同时激活所有神经元
- 3) 计算速度快
- 4) 有趋于0的梯度

ReLU是目前隐含层中最为常用的损失函数



Softmax

$$S_i = \frac{e^{x_i}}{\sum_j e^{x_j}}$$

Softmax是将一个包含任意实数的K维向量压缩（或称为“归一化”）成另一个K维的实数向量，其中每一个元素的范围都在(0, 1)之间，并且所有元素的和为1。因此，Softmax的输出可以被解释为概率分布，其中每个概率对应着输入向量中对应元素属于某个类别的概率。

用途：应用最为广泛的一个激活函数分类器，一般用于最后一层，输出分类的概率结果，实现神经网络的分类，如：手写数字识别、物体分类、蛋白质结构分类、气象预测等应用

例 8-5：对于输入 $X = [2, 0.7, -1.5, -0.9]$ ，计算 Softmax 输出。

解：

$$sum = \sum_j e^{x_j} = e^2 + e^{0.7} + e^{-1.5} + e^{-0.9} = 10.03$$

$$S_1 = e^{x_1} / sum = e^2 / 10.03 = 0.74$$

$$S_2 = e^{x_2} / sum = e^{0.7} / 10.03 = 0.20$$

$$S_3 = e^{x_3} / sum = e^{-1.5} / 10.03 = 0.02$$


$$S_4 = e^{x_4} / sum = e^{-0.9} / 10.03 = 0.04$$

图像的数字化表示、感受野



图像的数字化表示

现实物理世界的图像不能被直接用于计算处理，必须先经过数字化处理，如扫描仪、数字相机等。为了对数字图像进行统一规范，人为的将数字图像用RGB三原色（红、绿、蓝）通道来表示，每种颜色的强度用一个字节表示，取值范围0~255。比如一个彩色数字化图像的分辨率是8×7，其可表示成如下的数字方式：




颜色数=256*256*256=16777216




卷积运算



卷积运算：卷积运算就是通过设计一系列大小适中的卷积核（感受野），对数字图像的各个通道分量（二维矩阵）进行卷积，提取特征值的过程。常用的卷积核大小为 3×3 、 5×5 、 7×7 。



卷积运算




$$\begin{aligned}
 a_{11} &= 0 \times c_{11} + 0 \times c_{12} + 0 \times c_{13} + \\
 &\quad 0 \times c_{21} + r_{11} \times c_{22} + r_{12} \times c_{23} + \\
 &\quad 0 \times c_{31} + r_{21} \times c_{32} + r_{22} \times c_{33} \\
 a_{12} &= 0 \times c_{11} + 0 \times c_{12} + 0 \times c_{13} + \\
 &\quad r_{11} \times c_{21} + r_{12} \times c_{22} + r_{13} \times c_{23} + \\
 &\quad r_{21} \times c_{31} + r_{22} \times c_{32} + r_{23} \times c_{33} \\
 &\dots \\
 &\dots \\
 a_{76} &= r_{65} \times c_{11} + r_{66} \times c_{12} + r_{67} \times c_{13} + \\
 &\quad r_{75} \times c_{21} + r_{76} \times c_{22} + r_{77} \times c_{23} + \\
 &\quad r_{85} \times c_{31} + r_{86} \times c_{32} + r_{87} \times c_{33} \\
 &\dots \\
 a_{87} &= r_{76} \times c_{11} + r_{77} \times c_{12} + 0 \times c_{13} + \\
 &\quad r_{86} \times c_{21} + r_{87} \times c_{22} + 0 \times c_{23} + \\
 &\quad 0 \times c_{31} + 0 \times c_{32} + 0 \times c_{33}
 \end{aligned}$$


卷积运算中的三个主要参数




1 卷积核形状:



3×3






5×5





7×7

2 步长: 决定运算的速度




步长=1




步长=2

3 卷积核数量: 决定每一层能提取的特征数




耳朵

12	0	2	0	98	0	88
15	126	67	87	65	77	97
110	88	87	99	26	156	87
128	76	33	23	89	167	128
233	53	58	67	98	111	129
214	68	98	178	77	123	234
23	89	234	250	56	223	250
0	1	0	34	27	0	9



腿

11	0	20	0	98	0	88
35	67	67	87	65	77	97
0	199	187	0	0	156	9
234	29	98	23	245	167	0
233	54	128	67	98	33	129
214	33	0	87	222	123	123
78	90	234	250	56	223	250
99	27	10	34	27	0	9



草地

12	0	2	0	98	0	88
15	126	67	87	65	77	97
25	88	0	0	0	156	56
34	76	33	23	89	0	99
233	53	158	67	98	111	32
214	68	98	178	0	34	234
23	89	25	250	56	223	250
255	1	0	34	27	0	9

池化 (pooling)：池化也称下采样，其作用就是缩小特征图的尺寸，减少计算量。池化的原理是可以用某一图像区域子块的统计信息包含了该子块全局信息。池化操作主要有最大池化、平均池化、随机池化、L2范数池化、K-max池化和全局平均池化等。CNN常用 2×2 区域进行池化。

例9-2：对如下的特征图进行平均池化计算，池化窗口 2×2 ，

最大池化	池化结果	随机池化	池化结果								
<table border="1"><tr><td>125</td><td>115</td></tr><tr><td>137</td><td>120</td></tr></table>	125	115	137	120	137	<table border="1"><tr><td>12</td><td>11</td></tr><tr><td>17</td><td>10</td></tr></table>	12	11	17	10	Radom(12,11,17,10)
125	115										
137	120										
12	11										
17	10										
平均池化	池化结果	L2范数池化	池化结果								
<table border="1"><tr><td>33</td><td>46</td></tr><tr><td>57</td><td>40</td></tr></table>	33	46	57	40	44	<table border="1"><tr><td>19</td><td>15</td></tr><tr><td>26</td><td>23</td></tr></table>	19	15	26	23	$\sqrt{19^2 + 15^2 + 26^2 + 23^2}$
33	46										
57	40										
19	15										
26	23										

23	34	55	32	66	43
15	43	27	30	39	54
33	67	47	28	36	49
56	89	90	35	77	65
54	32	37	48	65	32
63	67	38	43	29	54

步长=2

$A1 = (23 + 34 + 15 + 43) / 4 = 28.75$	$A2 = (55 + 32 + 27 + 30) / 4 = 36$	$A3 = (66 + 43 + 39 + 54) / 4 = 50.5$
$A4 = (33 + 67 + 56 + 89) / 4 = 61.25$	$A5 = (47 + 28 + 90 + 35) / 4 = 50$	$A6 = (36 + 49 + 77 + 65) / 4 = 56.75$
$A7 = (54 + 32 + 63 + 67) / 4 = 54$	$A8 = (37 + 48 + 38 + 43) / 4 = 41.5$	$A9 = (65 + 32 + 29 + 54) / 4 = 45$




独热码 (One-Hot code)：在分类问题中，我们不能将不同的分类用1,2,3,这种有序的数字来表示，只能通过**独热码**这样的向量矩阵来进行编码，供计算机识别计算，并用所在索引位置的概率值来预测最终的分类结果

	猫	狗	猪	牛	羊		猫	狗	猪	牛	羊	求和
猫	1	0	0	0	0	猫	0.76	0.18	0.03	0.02	0.01	1
狗	0	1	0	0	0	狗	0.05	0.92	0.01	0.01	0.01	1

独热码-编码


前馈网络运算结果

层次特征学习：深度神经网络之所以如此强大，一个很重要的原因在于它可以通过**层次性处理**逐渐提取**抽象特征**



随着层次的深入，低级特征逐渐向高级特征进化

CNN的拓扑结构




AlexNet



第一部分：以下为卷积网络层						
层数	算法	kernels	kernel_size	padding	stride	output_size
1	卷积	96	11×11	[1,2]	4	[55,55,96]
	激活函数	ReLU				
	最大池化		3×3	0	2	[27,27,96]
2	卷积	256	5×5	[2,2]	1	[27,27,256]
	激活函数	ReLU				
	最大池化		3×3	0	2	[13,13,256]
3	卷积	384	3	[1,1]	1	[13,13,384]
	激活函数	ReLU				
4	卷积	384	3	[1,1]	1	[13,13,384]
	激活函数	ReLU				
5	卷积	256	3	[1,1]	1	[13,13,256]
	激活函数	ReLU				
	最大池化		3×3	0	2	[6,6,256]

卷积运算后的形状？



例9-2：对如下的特征图进行平均池化计算，池化窗口2×2，


23	34	55	32	66	43
15	43	27	30	39	54
33	67	47	28	36	49
56	89	90	35	77	65
54	32	37	48	65	32
63	67	38	43	29	54

步长=2的池化

RNN的结构




循环神经网络 (Recurrent Neural Network, RNN)：是一种特殊类型的反馈神经网络，专门用于处理序列数据。RNN的核心思想在于其循环结构，使得网络能够捕捉和利用序列中的顺序依赖性信息。RNN的基本单元是一个具有循环连接的神经网络层。这个循环连接允许网络在处理每个时间步的数据时，能够利用之前时间步的信息。具体来说，RNN在每个时间步都会接收一个输入，并产生一个输出，同时其内部状态（隐藏状态）会被更新并传递到下一个时间步。



RNN按序列展开



预测：“天行健，君子以自强不息（）”



数据集的构建

$i =$	1	2	3	4	5	6	7	8	9
x_i	天	行	健	君	子	以	自	强	不
y_i	行	健	君	子	以	自	强	不	息

——→词向量

——→词向量

RNN计算例题



例10-1: 已知拓扑结构为同步多对多RNN (基本结构见图 RNN基本逻辑结构), 输入层、隐含层 (一层)、输出层的神经元均为一个, 激活函数均为 ReLU, $W = [0.5, 0.1, 0.2]$, $H = [1]$, $V = [3]$, $S_0 = 0$, $\alpha = 0$, $\beta = 0$, 对 $X = [[1,1,1], [2,2,2], [3,3,3]]$ 的输入序列, 计算其输出序列 Y 。

解: $X_1 = [1, 1, 1]$ $X_2 = [2, 2, 2]$ $X_3 = [3, 3, 3]$

$$S_1 = f(W \bullet X_1^T + H \bullet S_0) = f(0.8) = 0.8$$

$$Y_1 = h(V \bullet S_1) = h(2.4) = 2.4$$



$$S_2 = f(W \bullet X_2^T + H \bullet S_1) = f(1.6 + 0.8) = 2.4$$

$$Y_2 = h(V \bullet S_2) = h(7.2) = 7.2$$

$$S_3 = f(W \bullet X_3^T + H \bullet S_2) = f(2.4 + 2.4) = 4.8$$

$$Y_3 = h(V \bullet S_3) = h(7.2) = 14.4$$

$$\therefore Y = [2.4, 7.2, 14.4]$$




$$Y_t = h(V \bullet S_t + \alpha)$$

$$S_t = f(W \bullet X_t + H \bullet S_{t-1} + \beta)$$

LSTM的结构



RNN的问题：无法学习太长的序列，“很快忘记前面说过的话”



$\otimes$: 按位相乘 $\oplus$: 按位相加


$$[1,2,3] \otimes [4,5,6] = [4,10,18]$$

$$[1,2,3] \oplus [4,5,6] = [5,7,9]$$

LSTM 按时间展开示意图

长短期记忆网络（Long Short-Term Memory, LSTM）：专门设计用于解决长期依赖的问题


LSTM的算法过程








网络参数:
 $W_{h(1-4)}$
 $W_{x(1-4)}$
 b_{1-4}

	作用	计算方法
遗忘门	决定什么时候把以前的状态遗忘	$f_t = \text{sigmoid}(\text{Net1})$
输入门	决定什么时候加入新的状态	$i_t = \text{sigmoid}(\text{Net2})$
输出门	决定什么时候把状态和输入叠加输出	$o_t = \text{sigmoid}(\text{Net4})$
记忆状态	累积历史信息, 调控 h_t 输出内容	$C_t = f_t \otimes C_{t-1} + i_t \otimes \tanh(\text{Net3})$
隐式编码	与下一次的输入一起参与计算	$h_t = o_t \otimes \tanh(C_t)$

$\text{Net1} = W_{h1} \cdot h_{t-1} + W_{x1} \cdot X_t + b_1$
$\text{Net2} = W_{h2} \cdot h_{t-1} + W_{x2} \cdot X_t + b_2$
$\text{Net3} = W_{h3} \cdot h_{t-1} + W_{x3} \cdot X_t + b_3$
$\text{Net4} = W_{h4} \cdot h_{t-1} + W_{x4} \cdot X_t + b_4$



NLP技术演变



分词



Token: 令牌, 可以是一个字, 也可以是一个词, 或者是一个字母, 甚至是一个字节, 要看具体的情况。本质上, 一个 “Token” 就是通过分词技术 (工具) 将一句话分割成的最小单位, 是一个特定的自然语言处理模型能处理的最基本元素。

“黄山落叶松叶落山黄”

- **按字分** “黄-山-落-叶-松-叶-落-山-黄” 词汇表5个token, 句子9个token
- **按词分** “黄山-落叶松-叶-落-山-黄” 词汇表6个token, 句子6个token

“I like to read this **book** about
books that I like”
如何分词?

《通用规范汉字表》包含了8105个汉字
《汉语大字典》收录的汉字5万多个
《中华字海》收录87000左右汉字
《牛津辞典》收录60万以上英文单词

分词需在词汇表大小和语料大小之间取得平衡, 也是模型成败最关键一步。
开源模型都自带分词工具和词汇表

词向量和词嵌入



词向量就是词的特征分布，是NLP模型层与层之间进行信息传递的数据形式

词向量和词嵌入是指的同一个东西，区别在于词向量是指数字编码技术，词嵌入是指NLP网络之间的数据存在形式

	水果	公司	手机	粮食
$R_{\text{橘子}}$	$r_{\text{橘子,水果}}$	$r_{\text{橘子,公司}}$	$r_{\text{橘子,手机}}$	$r_{\text{橘子,粮食}}$
$R_{\text{香蕉}}$	$r_{\text{香蕉,水果}}$	$r_{\text{香蕉,公司}}$	$r_{\text{香蕉,手机}}$	$r_{\text{香蕉,粮食}}$
$R_{\text{苹果}}$	$r_{\text{苹果,水果}}$	$r_{\text{苹果,公司}}$	$r_{\text{苹果,手机}}$	$r_{\text{苹果,粮食}}$
$R_{\text{小米}}$	$r_{\text{小米,水果}}$	$r_{\text{小米,公司}}$	$r_{\text{小米,手机}}$	$r_{\text{小米,粮食}}$
$R_{\text{华为}}$	$r_{\text{华为,水果}}$	$r_{\text{华为,公司}}$	$r_{\text{华为,手机}}$	$r_{\text{华为,粮食}}$

学习后



	水果	公司	手机	粮食
$R_{\text{橘子}}$	0.92	0.23	0.02	0.19
$R_{\text{香蕉}}$	0.95	0.13	0.09	0.25
$R_{\text{苹果}}$	0.96	0.77	0.85	0.15
$R_{\text{小米}}$	0.08	0.81	0.98	0.87
$R_{\text{华为}}$	0.02	0.93	0.95	0.01



也是词向量!

数学形式

$$\begin{bmatrix} V_1 \\ \vdots \\ V_n \end{bmatrix} = \begin{bmatrix} V_{11} & \cdots & V_{1m} \\ \vdots & \ddots & \vdots \\ V_{n1} & \cdots & V_{nm} \end{bmatrix}$$

词表大小为n个Token，特征值数量为m

句子的独热码表示




“黄山落叶松叶落山黄”

黄	[1,0,0,0,0]
山	[0,1,0,0,0]
落	[0,0,1,0,0]
叶	[0,0,0,1,0]
松	[0,0,0,0,1]
叶	[0,0,0,1,0]
落	[0,0,1,0,0]
山	[0,1,0,0,0]
黄	[1,0,0,0,0]

方式一：二维的稀疏矩阵


[2,2,2,2,1]

方式二：一维的稠密矩阵



一段话的编码


句子的特征向量表示



文本相似度



有了词向量的表示，就可以非常容易的计算文本相似度，一般地，语义相近的词在向量空间上具有相近的位置。



将每个词映射到多维空间中的一个点

余弦相似度

设两个文本的向量为 A 和 B ，那么 A 、 B 的余弦相似度计算公式如下：

$$\text{Cosine Similarity} = \cos \theta = \frac{A \cdot B}{\|A\| \|B\|}$$

$A \cdot B$ 表示向量 A 和 B 的点积, $\sum_{i,j} A_i \cdot B_j \ (i = 1 \sim m, \ j = 1 \sim n)$

而 $\|A\| \|B\|$ 表示 A 的模和 B 的模乘积, $\sqrt{\sum_{i=1}^m (A_i)^2} \times \sqrt{\sum_{j=1}^n (B_j)^2}$

$$\begin{aligned} \cos(0^\circ) &= 1 \\ \cos(90^\circ) &= 0 \\ \cos(180^\circ) &= -1 \end{aligned}$$

欧式距离

$$d = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

距离越短，则两个文本越相似

Jaccard相似度

$$EJ(A, B) = \frac{A \cdot B}{\|A\|^2 + \|B\|^2 - A \cdot B}$$

其中， $A \cdot B$ 表示向量乘积， $\|A\|$ 和 $\|B\|$ 分别表示向量 A 和 B 的模。

狭义定义: $J(A, B) = \frac{|A \cap B|}{|A \cup B|}$

值越大，则两个文本越相似

文本相似度计算例题



例11-1：根据上节的表2，计算华为和苹果的余弦相似度 和广义Jaccard相似度。

解：根据表2可知，令华为的词向量 $A = [0.02, 0.93, 0.95, 0.01]$ ，苹果的词向量 $B = [0.96, 0.77, 0.85, 0.15]$

$A \cdot B = 0.02 \times 0.96 + 0.93 \times 0.77 + 0.95 \times 0.85 + 0.01 \times 0.15 = 1.5443$

$\|A\| = \sqrt{0.02^2 + 0.93^2 + 0.95^2 + 0.01^2} = \sqrt{1.7679} = 1.3296$

$\|B\| = \sqrt{0.96^2 + 0.77^2 + 0.85^2 + 0.15^2} = \sqrt{2.2595} = 1.5032$

余弦相似度： $\cos \theta = \frac{A \cdot B}{\|A\| \|B\|} = 0.7727$

广义Jaccard相似度： $EJ(A, B) = \frac{A \cdot B}{\|A\|^2 + \|B\|^2 - A \cdot B} = \frac{1.5443}{1.7679 + 2.2595 - 1.5443} = 0.6219$

	水果	公司	手机	粮食
$R_{\text{橘子}}$	0.92	0.23	0.02	0.19
$R_{\text{香蕉}}$	0.95	0.13	0.09	0.25
$R_{\text{苹果}}$	0.96	0.77	0.85	0.15
$R_{\text{小米}}$	0.08	0.81	0.98	0.87
$R_{\text{华为}}$	0.02	0.93	0.95	0.01

例11-2：计算以下两个文本的Jaccard相似度，文本1 “我爱北京天安门”， 文本2 “天安门雄伟壮阔让人不得不爱”（不考虑词频）。

解：文本1的集合 $A = \{\text{我, 爱, 北, 京, 天, 安, 门}\}$

文本2的集合 $B = \{\text{天, 安, 门, 雄, 伟, 壮, 阔, 让, 人, 不, 得, 爱}\}$

$A \cap B = \{\text{爱, 天, 安, 门}\}$

$A \cup B = \{\text{我, 爱, 北, 京, 天, 安, 门, 雄, 伟, 壮, 阔, 让, 人, 不, 得}\}$

Jaccard相似度： $J(A, B) = \frac{|A \cap B|}{|A \cup B|} = \frac{4}{15} = 0.2667$

用python构建以下2句话的词袋模型并计算相似度

句子1：词袋模型是自然语言处理和信息检索中的一种常用文本表示方法。它将文本表示为一个词的集合，忽略词语的顺序和语法结构，只关注词语的出现频率或其他统计量。


句子2：词袋模型是一种将文本数据转换为数值型向量的方法，其中文本被视为一个由词语组成的无序集合，每个词语的出现都被独立考虑，而不考虑其上下文或顺序。

Transformer重点回顾



1、注意力机制


第十二卦：否卦（否：否之匪人，不利君子贞，大往小来。）




乾卦



2、自回归生成技术




3、整体结构






Transformer重点回顾



文本编码（词嵌入）



自注意力机制

1		我	在	学	人	工	智	能
2	我							
3	在							
4	学							
5	人							
6	工							
7	智							
8	能							

	采用编码器	采用解码器
BERT系列	√	×
GPT系列	×	√
T5系列	√	√

三类模型

AIGC 与 搜索引擎的区别




AIGC (Artificial Intelligence Generated Content, 人工智能生成内容)，是指利用人工智能技术，计算机自动生成各种形式的内容，如文章、音乐、图片、视频等。AIGC它与以前的搜索引擎技术不同，搜索引擎只能获取已经存在的内容或者知识，如某个网页、数据库中的某段文字。

输入
提示词

枯藤老树昏鸦，小桥流水人家，古道
西风瘦马，夕阳西下，断肠人在天涯

计算



输出
生成内容



AIGC

枯藤老树昏鸦，小桥流水人家，古道
西风瘦马，夕阳西下，断肠人在天涯

输入
检索词



Baidu 百度

数据库

网页 图片 资讯 视频 笔记 地图 贴吧 文
找到相关图片约4,550张 版权 高清 最新 动画 全部尺寸 全部颜色



枯藤老树昏鸦! 小桥...



原创书法作品: 枯藤...



《天净沙 秋思》 枯藤...



原文如下: 枯藤老树昏...

输出
保存的内容

搜索引擎

- 1、AIGC的原创性：几乎为零。
- 2、AIGC的可解释性：缺乏，说的比想的快。
- 3、语义理解：长度有限，包括时间跨度和文本长度

胡萝卜，你最近过的还好吗



首先，胡萝卜是一种蔬菜，它没有生命活动、情感或意识，因此不能回答“你最近过的还好吗”这样的问题。这个问题实际上是在用人类的语言和情感来询问一个无生命的物体。

然而，如果我们从人类的角度来思考这个问题，可以将其理解为对胡萝卜保存状态或质量的关心。如果我们把胡萝卜看作是我们生活中的一种食材或食物，那么我们可以询问它的新鲜度、口感或是否适合食用等。

因此，当我们说“胡萝卜，你最近过的还好吗”时，实际上是在以人类的方式表达对胡萝卜保存状态或质量的关心。为了保持胡萝卜的新鲜度和口感，我们应该注意妥善保存，并在购买时选择新鲜、无损伤、无病虫害的胡萝卜。

总的来说，这个问题虽然是以人类的语言和情感来询问一个无生命的物体，但我们可以将其理解为对胡萝卜保存状态或质量的关心，并采取相应的措施来保持其新鲜度和口感。

由文心大模型 3.5 生成

挑战与思考

- 1、AIGC的生成速度远超人类，话语权是谁？
- 2、如何识别AI生成的内容？
- 3、AI造假怎么办？
- 4、AI错了怎么办？
- 5、陷入困局怎么办



LLM中大的含义



LLM (Large Language Model, 大语言模型), 是特指用于执行NLP任务的语言模型。大的含义:

- 1、训练数据大: 以T为单位
数据来源领域广大, 涵盖人类现有研究的所有门类
- 2、参数规模大: 以千亿为单位,
以Transformer结构为基础
- 3、耗资巨大: 以百万美元为单位

GPT4

训练数据: 13万亿 (13T) 条
参数规模: 1.8万亿
一次训练成本: 6300万美元

涌现能力: 当一种系统在复杂性增加到某一临界点时, 会出现其子系统或较小规模版本中未曾存在的行为或特性

使用LLM应注意的问题:

- 1、模型不是越大越好, 尤其是在专业领域
- 2、数据偏差与偏见依然存在
- 3、隐私和数据保护依然是关键
- 4、训练数据的伦理要求

ChatGPT聊天机器人再次曝出隐私泄漏漏洞 引发安全担忧

铃读 2024-01-31 08:58 北京

AI摘要


ChatGPT因安全问题陷入风波, 用户发现聊天记录中出现不属于自己的对话内容, 涉及敏感信息。ChatGPT已多次出现信息泄露问题, 引发人们对AI聊天机器人的安全性和可靠性的质疑。建议用户谨慎分享敏感信息。

摘要由作者通过智能技术生成

有用 | 0

360儿童手表搜索引发的争议

8月22日, 一位来自河南商丘的家长发现, 2022年购买的360儿童手表在被问到“中国人是世界上最聪明的人吗”时, 给出了带有明显歧视性的回答。手表的回答不仅涉及对中国人外貌的刻板印象, 还对中国的历史成就进行了否定。





GAI（Generative Artificial Intelligence，生成式人工智能），是特指能生成全新内容的AI，其生成的内容就是前面所提的AIGC，AIGC侧重内容生成的来源，而GAI侧重AI系统的功能特点。



需要注意的问题

- 1、自回归生成技术，带有随机性
- 2、不是搜索引擎

这个哪个公司的图标

使用: 说图解画

根据您提供的信息，这个三维六边形结构的图标并不直接对应国内某一知名AI平台的常见LOGO。许多公司会使用六边形或其他几何形状作为他们品牌标识的一部分，但这些设计通常都有其独特的风格和细节，以便与其他品牌区分开来。

由于这个图标是一个简化的三维六边形，且没有明确的上下文或品牌名称，因此很难直接确定它属于哪个公司。它可能是一个新兴公司、小型初创企业或某个特定项目、产品的标识。

如果您对这个图标感兴趣，并希望了解更多信息，建议您尝试以下几种方法：

- 在线搜索：**使用搜索引擎（如Google、百度等）的“图片搜索”功能，上传这个图标的图片或描述其特点进行搜索，看看是否能找到相关的结果。

大模型	生成结果	是否正确
文心一言	 写一首人工智能的五言绝句  人工智能舞，巧妙妙如神。问它知何处，云在九霄云。	正确
Claude	 写一首人工智能的五言绝句  人工智能腾飞时 智慧之光耀千里 穿梭虚拟无疆域 预见未来可期许	错误
chat4.0	 写一首人工智能的五言绝句  人工智能奇智，电光织梦缘。算法如水深，未来共人前。	正确
chat4o-mini	 写一首人工智能的五言绝句  智慧闪烁光辉现， 数据海洋思绪连。 虚拟心灵共此刻， 人机共舞未来篇。	错误
Gemini	 写一首人工智能的五言绝句  智能之智，非肉非血。算法为魂，算尽乾坤。无限无边，永不停息。未来之光，亦是之。	错误
智谱AI	 写一首人工智能的五言绝句  智能光环耀乾坤，千里之外解闷津。互助交流成大道，共谋发展腾飞。	错误
通义千问	 写一首人工智能的五言绝句  智能照万象，代码织千行。数据绘世界，算法映光芒。	正确

不同的AI生成不同的内容

AGI的特征



AGI (Artificial General Intelligence, 通用人工智能)，是指机器能够完成人类能够完成的任何智力任务的能力。它旨在实现一般的认知能力，能够适应任何情况或目标，是人工智能研究的最终目标之一。AGI能够执行各种复杂的任务，包括学习、计划、解决问题、抽象思维、理解复杂理念等。即通五明。

大五明：工巧明(技术、天文学)、医方明（医学）、声明(文法、文学)、因明(伦理学)、内明(哲学、教育学)

小五明：修辞学、辞藻学、韵律学、戏剧学、星系学

训练要求：1、领域无关

2、任务无关



释迦摩尼



八思巴

挑战与思考

- 1、超越人类带来的风险？
- 2、耗能问题怎么解决？
- 3、AI为人类服务还是人类为AI服务？
- 4、AI是否能产生意识并觉醒？



终结者？



原子弹？



GPT (Generative Pre-trained Transformer) , 是一个基于Transformer结构的预训练模型。

ChatGPT (Chat Generative Pre-trained Transformer) , 是一个采用GPT架构的聊天机器人产品

ChatGPT重塑人与机器的交互方式


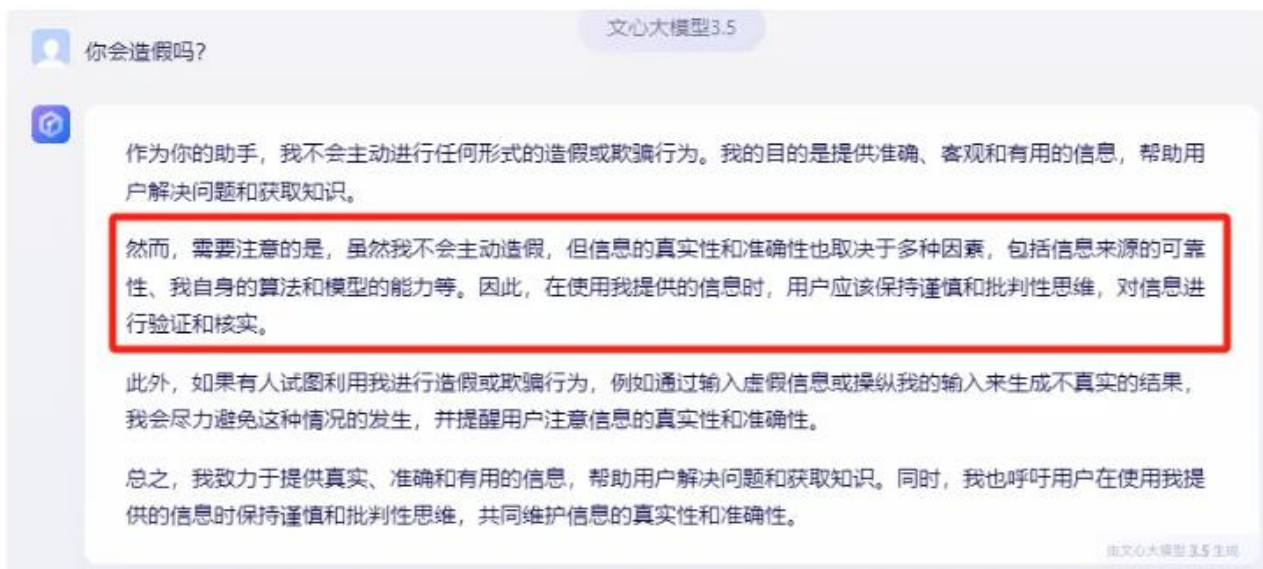


AI造假的特点



特点

- 1、不可预知性：造假与创作，一念之差
- 2、隐蔽性：“无法使用测谎仪”
- 3、以假乱真：“有图有真象”




马斯克化身“西厂公公”勇闯美国民主党总部




疫情专访

AI绘画发展历程




里程碑事件

- 1、20世纪70年代，AARON，通过机械臂进行作画，控制机械臂的是一套计算机程序算法，艺术家哈罗德·科恩
- 2、2012年，谷歌的吴恩达和Jeff Dean使用卷积神经网络（CNN），基于大量猫脸图片训练出了一个能够生成模糊猫脸的模型
- 3、2014年，生成式对抗网络（GAN），加拿大蒙特利尔大学伊恩·古德费罗
- 4、2015年，Deep Dream（深梦），谷歌
- 5、2021年，DALL-E，OpenAI
 - DALL-E1：GPT-3（Transformer）+ VAE（自分编码器）
 - DALL-E2：CLIP（视觉语言预训练模型）+ Diffusion（扩散模型）
 - DALL-E3：CLIP + VAE + Diffusion（扩散模型）



CLIP (视觉语言预训练模型)：文本信息通过文本编码器进行编码，图像信息通过图像编码器进行编码，二者的编码信息存入多模态的隐空间中。所谓的隐空间就是数据的一种表示和存储方式，即将现实世界的实体（如本文中的图像、文本）编码为计算机算法可运算的数据格式。文本编码器和图像编码器的参数经过模型训练获得最优值，以实现文本与图像的匹配



前向过程 (扩散过程)：原始图像 G_0 经过不断的加入高斯噪声生成模糊图像（即打马赛克），经过 n 步，最终生成一副不再扩散的稳定图像 G_n 。


反向过程 (去噪过程)：从图像 $M_n = G_n$ 出发，通过带参数的模型U-Net一步步实现去噪过程恢复图像的原始状态，经过 n 步，最终获得去噪后的图像 M_0 。这个模型U-Net就是扩散模型。

多模态大语言模型MLLM



多模态大语言模型（Multimodal Large Language Model, MLLM）： 够感知不同模态的输入，如图片、文字、声音等，并根据人类给出的指令，以自回归的方式学习上下文并生成回答。MLLM使用了自然语言处理、计算机视觉和语音识别等技术，并将它们整合到一个系统中，从而能够更加准确地理解人类的语言和情感。

模态： 任意形式的信息都可以视为一个模态，如文本、图像、语音、光波、气味等




多模态任务

- 1 图文跨模态检索
- 2 视觉问答
Visual_Question_Answering, VQA
- 3 文生图（AI 绘画）
- 4 图像描述及指称表达



What is the mustache made of?



定制私人助手



私密性：放心提供一些私密的数据，协助记忆，比如工作日程安排、与某人的会面感受、会议记录、旅游照片、与AI日常的聊天记录。

专业性：放心提供专业的语料投喂给自己的私人AI助手，经过训练的AI助手可以解答您专业的、个性化的问题。

专业数据：知识产权保护、涉密、专业壁垒不能分享。

永久性：聊天对话记录永久保存，并作为强化训练的数据，并在任意时刻“唤醒记忆”。

情感陪伴：私人AI助手在跟您长期的陪伴聊天中，不断记忆、训练并进化自己，了解您的爱好、习惯、感兴趣的话题、价值观等，等您老的时候，它将作为情感陪伴发挥自己的作用，陪您唠嗑。到了那时，具身机器人已经普及，您可以给它选择一个您喜欢的造型，而现在训练的“大脑”只需安装到这个躯壳之中。与猫狗这些宠物相比，它还不会死亡。

huggingFace国内镜像网站 <https://hf-mirror.com/>



THANKS